

spark-2 온프레미스 AI · API 사용 안내

삼성창원병원 AI 업무지원 교육 — spark-2 서버의 AI 모델을 내 코드에서 직접 호출하는 방법

🔒 온프레미스 처리. 추론은 spark-2 서버에서 수행됩니다. 인증(API Key) 없이 호출하니, 환자정보·對外秘 자료는 입력하지 마세요(더미·비식 별만).

1. 접속 주소

방법	주소	언제
① 외부망(인터넷)	<code>http://121.138.151.6:11434</code>	어디서나 — 기본
② SSH 터널	<code>ssh -L 11434:localhost:11434 spark-2 → http://localhost:11434</code>	더 안전하게 쓰고 싶을 때

원내망 PC라면 `http://192.168.100.6:11434` 도 가능합니다.
방법 ②는 터널을 연 뒤, 주소의 `121.138.151.6` 자리를 `localhost` 로 바꿔 호출하세요.

2. 사용할 모델

용도	모델 이름	비고
채팅(생성)	<code>qwen3.6:35b-a3b</code>	35B MoE · 한국어 우수
임베딩(검색용 벡터)	<code>bge-m3:latest</code>	다국어

전체 목록 확인: `curl`
`http://121.138.151.6:11434/api/tags`

3. 호출 방법 (예제)

(1) 채팅 — 터미널(curl)

```
curl http://121.138.151.6:11434/api/chat -d '{
  "model": "qwen3.6:35b-a3b",
  "messages": [
    { "role": "user", "content": "외래 진료시간을 안내
해줘" }
  ],
  "stream": false
}'
```

응답의 `message.content` 에 답변이 들어 있습니다.

(2) 채팅 — Python

```
import requests

res =
requests.post("http://121.138.151.6:11434/api/cha
t", json={
  "model": "qwen3.6:35b-a3b",
  "messages": [{"role": "user", "content": "안녕
하세요, 한 문장으로 인사해줘"}],
  "stream": False,
})
print(res.json()["message"]["content"])
```

(3) 임베딩(검색·RAG용)

```
curl http://121.138.151.6:11434/api/embeddings -d
'{
  "model": "bge-m3:latest",
  "prompt": "환자 안내문 한 문장"
}'
```

응답의 `embedding` 이 숫자 벡터(검색에 사용).

(4) ollama 명령어로 바로 대화 (선택)

```
OLLAMA_HOST=121.138.151.6:11434 ollama run  
qwen3.6:35b-a3b
```

4. 안전 수칙 (필독)

- 환자정보 · 對外秘 자료 입력 금지 — 더미·비식별 데이터만 사용하세요.
- 인증이 없는 공유 서버입니다 — 대용량·반복 호출은 자제(다른 수강생과 공유).
- 추론은 spark-2에서 수행됩니다. 단, 입력 데이터는 본인이 책임집니다.
- 주소·접속법은 외부에 공유하지 마세요(내부 교육 자료).

부록 · 빠른 점검

```
# 연결 확인 (버전)  
curl http://121.138.151.6:11434/api/version  
  
# 모델 목록  
curl http://121.138.151.6:11434/api/tags
```

문의: 정보지원팀 · 강의 진행자