

02. 원무팀 — 콜센터 안내 챗봇 A RAG 챗봇

❗ 이 페이지 전제 — 복붙 전 1초 확인 (Sonnet도 그대로 동작하게 다 적었습니다) - 답변(채팅) 모델: **qwen3.6:35b-a3b** · 호출 **POST**
http://121.138.151.6:11434/api/chat - (참고) 검색(임베딩) 모델 **bge-m3:latest** 은 다음 강의용 — 이번 숙제에서는 쓰지 않습니다(자료를 통째로 모델에 넘김). - 내 백엔드: FastAPI
http://127.0.0.1:8000 — 프론트(HTML)는 반드시 이 백엔드만 부릅니다. - 🚫 금지: HTML/자바스크립트에서 **11434** · **ollama** 직접 호출 금지(CORS·보안 사고). 모델 호출은 오직 백엔드(8000) 경유. - 출발점: 공통 **STEP 0** 기본코드(**app.py** · **index.html**)가 떠 있는 상태에서 시작(이 페이지에 코드를 다시 만들지 않음). - 🐦 전제: 공통 **STEP 0**의 백엔드 **/api/chat** 응답은 이미 **SSE 스트림(data: 줄)**입니다 — 프론트는 그 줄을 받아 답변창을 한 글자씩 채웁니다.

한 줄: 병원 이용안내(외래시간·주차·면회·증명서·접수수납 등)를 상담원/환자가 **자연어로 묻고**, 챗봇이 **자료 근거·출처와 함께** 자연어로 답하는 콜센터 안내 Q&A 챗봇. **최종 화면(도달선):** 표·버튼이 주인공이 아니라 **질문 입력창 + 답변창(+📎 출처 표시)** 의 대화 챗봇입니다. FAQ 버튼은 자주 묻는 질문을 입력창에 자동으로 넣어주는 **보조일 뿐**, 모든 답은 챗봇 답변창에 자연어로 나옵니다. **이번 주 목표:** 공통 챗봇(프론트→내 백엔드 **http://127.0.0.1:8000** →채팅 모델 **qwen3.6:35b-a3b** @ **http://121.138.151.6:11434/api/chat**)에 안내 자료를 **통째로 컨텍스트에 넣어(stuffing)** 질문하면 **자료의 어느 항목인지 출처를 붙여** 답하게 만들기. 자료에 없으면 지어내지 말고 “확인 불가”.

📌 꼭 기억: 화면(HTML)은 내 백엔드(**http://127.0.0.1:8000**)만 부릅니다. 모델(**http://121.138.151.6:11434 / ollama:11434**)을 브라우저에서 직접 부르지 않습니다(반드시 백엔드 경유). 이번 숙제는 **임베딩 검색 없이** 참고 자료를 통째로 넘기는 “컨텍스트(stuffing) 방식”입니다(진짜 임베딩 검색은 다음 강의).

📖 도메인 샘플 자료 (콜센터 이용안내 — 더미)

아래는 실제처럼 보이도록 만든 **연습용 더미**입니다. 실제 병원 정보·환자 정보는 절대 넣지 마세요. 항목마다 **[Q번호]** 출처표를 붙여, 챗봇이 “어느 항목 근거인지” 답하기 쉽게 했습니다.

[병원 이용안내 - 콜센터 응대용 / 더미]

[Q1] 외래 진료시간

- 평일 09:00~17:30, 토요일 09:00~12:30
- 점심시간 휴진 12:30~13:30 (토요일은 휴진시간 없음)
- 일요일·공휴일 외래 휴진 (응급실은 24시간 운영)

[Q2] 주차 안내

- A주차장(본관 지하): 최초 30분 무료, 이후 30분당 1,000원
- B주차장(별관): 1시간 2,000원, 1일 최대 15,000원
- 진료·검사 당일 외래환자 3시간 무료(수납창구 또는 무인정산기에서 주차권 등록)
- 입원환자 보호자 1일 5,000원 정액(병동 간호사실에서 확인 도장)
- 장애인 등록차량 50% 감면

[Q3] 면회 안내

- 일반병동 면회: 평일 18:00~20:00 / 주말·공휴일 10:00~12:00, 18:00~20:00
- 중환자실 면회: 1일 1회, 1회 10분, 보호자 2인 이내(별도 시간 안내)
- 1세 미만 영유아 동반 면회 제한

[Q4] 증명서 발급

- 발급장소: 1층 원무과 제증명 창구
- 운영시간: 평일 09:00~17:00 (점심 12:30~13:30 제외)
- 종류: 진단서, 입퇴원확인서, 진료확인서, 납입증명서
- 본인 외 발급 시 위임장·신분증 사본 필요
- 온라인 발급: 병원 누리집 '증명서 발급' 메뉴(공동인증서 필요)

[Q5] 접수·수납

- 초진 접수: 1층 원무과 또는 누리집 사전등록 후 방문
- 재진 예약: 콜센터 또는 모바일 앱에서 가능
- 수납: 외래 1층 수납창구·무인수납기, 카드/현금/간편결제
- 진료비 영수증 재발급: 수납창구 또는 누리집

[Q6] 진료과 위치 안내

- 내과·가정의학과: 본관 2층
- 정형외과·재활의학과: 본관 3층
- 소아청소년과·산부인과: 별관 2층
- 영상의학과(검사): 본관 지하 1층
- 채혈실·진단검사: 본관 1층

[Q7] 휴진·변경 안내

- 매월 셋째 주 수요일 오후: 전산 정기점검으로 오후 외래 단축 운영
- 의료진 사정으로 당일 휴진이 생기면 예약환자에게 문자 안내
- 공휴일 다음 날 오전은 혼잡(대기 길어질 수 있음)

[Q8] 자주 묻는 기타

- 진료의뢰서(소견서): 1·2차 병원에서 지참 시 선택진료 가능
- 모바일 앱: 예약·수납·검사결과·주차정산 가능
- 콜센터 운영: 평일 08:30~17:30 (점심 무중단)

복붙 프롬프트 (공통 ①②③ 끝낸 뒤, 순서대로)

프롬프트 1 — 콜센터용으로 기본 세팅

지금 만든 공통 챗봇을 "병원 콜센터 안내용"으로 바꿔줘.

- 백엔드(app.py, <http://127.0.0.1:8000>)가 채팅 모델을 호출하는 부분은
반드시 POST <http://121.138.151.6:11434/api/chat> ,
body는 {"model": "qwen3.6:35b-a3b", "messages": [...], "stream": true} 로 한다(응답 본문 message.content).
- (프론트 index.html은 절대 11434/ollama를 직접 부르지 말고, 오직 백엔드 :8000만 호출)
- (전제) 공통 STEP 0의 백엔드 /api/chat 응답은 이미 SSE 스트림(data: 줄)이다 - 프론트는 그 줄을 받아 답변을 한 글자씩 채운다. 이 속제는 검색 없이 참고자료를 통째로 넘기지만, 응답이 스트림이라는 점은 그대로다.
- index.html의 '참고자료' 입력칸 기본값(placeholder가 아니라 실제 값)으로
아래 '병원 이용안내 - 더미' 자료 전체를 넣어줘.
- 화면 제목을 "원무팀 콜센터 안내 도우미"로 바꾸고,
안내 문구 "※ 연습용 더미 자료입니다 (Demo)"를 작게 표시.
- 백엔드 시스템 프롬프트를 이렇게 바꿔줘:
"너는 병원 콜센터 상담원을 돕는 안내 도우미다.
반드시 제공된 참고 자료에만 근거해 한국어로 친절하고 간결하게 답한다.
자료에 없는 내용은 추측하지 말고 '확인되지 않습니다 - 담당 부서에 문의 바랍니다'라고 답한다.
환자번호·환자명 등 개인정보는 절대 묻지도, 답하지도 않는다."
(여기에 위 '병원 이용안내 - 더미' 자료 블록 전체를 붙여넣기)

🚫 **분리 강제:** HTML/자바스크립트에서 ollama(11434)를 직접 호출 금지.
모델 호출은 오직 백엔드 <http://127.0.0.1:8000> 경유. **기대 결과 (검증):** 화면을 열면 참고자료 칸에 안내 자료가 미리 채워져 있고, "주차요금?"이라고 물으면 자료 근거로 답한다. → **성공 기준: 브라우저 화면에 답변 텍스트가 뜨고, 서버 터미널에 121.138.151.6:11434/api/chat 호출 로그가 한 번 찍히면 OK.**

프롬프트 2 — 출처(근거 항목) 함께 표시 강화

답변할 때 항상 '근거'를 함께 보여줘.

- 답의 마지막에 "📎 근거: [Q2] 주차 안내" 처럼,
내가 준 자료에서 어느 항목([Q번호]·제목)을 보고 답했는지 표시해줘.
- 여러 항목을 참고했으면 모두 나열.
- 자료에 없어서 답을 못 하면 근거 대신 "📎 근거: 해당 자료 없음"이라고 표시.
- index.html에서 이 근거 줄은 회색 작은 글씨로 답변 아래에 보이게 해줘.
(index.html은 백엔드 :8000만 호출 - 모델 11434 직접 호출 금지)

기대 결과(검증): “면회 몇 시야?” → 답 + “📎 근거: [Q3] 면회 안내”가 함께 뜬다. → **성공 기준:** 답변 아래에 회색 작은 글씨로 📎 근거: [Q3] 면회 안내 줄이 보이면 OK.

프롬프트 3 — 자료 밖 질문(예외) 처리

참고 자료에 없는 질문이 들어올 때의 행동 규칙을 강화해줘.

- 예: “암 보험 되나요?”, “원장님 성함?”, “옆 건물 식당 추천” 등 자료에 없는 질문은 지어내지 말고 “확인되지 않습니다 - 담당 부서/콜센터에 문의 바랍니다”로 답한다.
- 다만 비슷한 안내가 자료에 있으면 “직접 답변은 어렵지만, 관련해 [Q5] 접수·수납 안내가 있습니다”처럼 연결 가능한 항목을 한 줄 제안한다.
- 의료적 진단·처방을 묻는 질문(예: “이 증상 무슨 병?”)은 안내 범위가 아님을 알리고 “진료 예약을 도와드릴까요?”로 응대한다.

(이 규칙은 백엔드 시스템 프롬프트에서 처리 - 프론트는 :8000만 호출, 모델 11434 직접 호출 금지)

기대 결과(검증): “원장님 누구야?” → 지어내지 않고 “확인되지 않습니다...” + 관련 안내 제안. → **성공 기준:** 화면에 확인되지 않습니다 문구가 보이고, 지어낸 이름이 안 나오면 OK.

프롬프트 4 — 숫자 계산은 코드로, 답변은 챗봇으로 (환각 방지)

“숫자 집계·정확 비교” 질문은 모델이 숫자를 지어내면 위험하다. 그래서 계산은 백엔드 코드로 정확히 하고, 그 값을 컨텍스트(근거)로 모델에 넘겨 모델이 그 값을 인용해 자연어로만 답하게 해줘. (모델이 직접 산수하지 않게)

- 백엔드 app.py에 주차요금 표를 파이썬 dict로 둔다:
A_FIRST_FREE_MIN=30, A_PER_30MIN=1000,
B_PER_HOUR=2000, B_DAY_MAX=15000,
OUTPATIENT_FREE_HOURS=3 (외래 당일 무료시간).
- 질문에서 “몇 시간 주차” 같은 시간이 보이면(예: “A주차장 2시간이면 얼마야?”), 백엔드가 코드로 정확히 계산한다:
2시간 = 120분 → 처음 30분 무료, 남은 90분 = 30분 단위 3 구간 × 1,000원 = 3,000원.
- 계산 결과를 “[계산결과] A주차장 2시간 = 3,000원 (처음 30분 무료, 이후 30분당 1,000원)” 형태의 한 줄 근거로 만들어, 자료 컨텍스트와 **함께** 채팅 모델에 넘긴다.
- 시스템 프롬프트에 “[계산결과] 줄이 있으면 그 숫자를 그대로 인용해 답하고, 절대 임의로 다른 숫자를 만들지 마라”를 추가한다.
- 계산이 필요 없는 질문(면회시간 등)은 지금까지처럼 자료 근거로만 답한다.

(계산·모델 호출 모두 백엔드 :8000에서 - 프론트 index.html은 11434 직접 호출 금지)

기대 결과(검증): “A주차장 2시간이면 얼마야?” → 챗봇 답변창에 “3,000원”이 자연어로 나오고, 출처에 계산 근거가 붙는다. **결정론적 정답값:** A주차장 2시간 = **3,000원**(120분 – 무료 30분 = 90분 = 30분×3 × 1,000원). “외래 당일 3시간 무료면 2시간 주차 얼마?” → **0원(무료)**. → **성공 기준:** 답변창에 정확히 **3,000원** (또는 무료 케이스 **0원**)이 뜨고, 모델이 엉뚱한 숫자를 지어내지 않으면 OK.

프론트 5 — ‘자주 묻는 질문’ 버튼 추가 (챗봇 입력 보조)

index.html의 챗봇 입력창 위에 자주 묻는 질문 버튼 5개를 추가해 줘.
(버튼은 답을 직접 그리지 않는다 – 어디까지나 챗봇 입력창에 질문을 넣어주는 보조다.)
– 버튼 라벨: “주차요금”, “외래 시간”, “면회 시간”, “증명서 발급”, “진료과 위치”
– 버튼을 누르면 해당 질문이 입력칸에 자동으로 들어가고 바로 전송되어,
 답은 평소처럼 챗봇 답변창에 자연어 + 📎 출처로 나오게.
– 버튼은 한 줄로 보기 좋게 배치(작은 알약 모양), 모바일에서도 잘 바꿈되게.
백엔드는 그대로 두고 프론트만 수정해줘.
(프론트 index.html은 백엔드 :8000만 호출 – 버튼이 모델 11434를 직접 부르게 만들지 말 것)

기대 결과(검증): “주차요금” 버튼 클릭 → 질문이 입력창에 자동 입력·전송되고, 답은 챗봇 답변창에 출처와 함께 뜬다. → **성공 기준:** 버튼 클릭만으로 입력칸에 “주차요금”이 채워지고 답변창에 자연어 답 + 📎 근거가 뜨면 OK.

프론트 6 — 디버깅 (안 될 때 함께 해결)

지금 화면에서 질문을 보내도 답이 안 나온다. 같이 원인을 찾아줘.
1) 백엔드(http://127.0.0.1:8000)가 떠 있는지 GET /health 로 먼저 확인해줘.
2) 브라우저 개발자도구(F12) 콘솔과 네트워크 탭에서 무슨 오류가 나는지 알려줘.
3) 흔한 원인 점검:
 – 프론트(index.html)가 백엔드 :8000이 아니라 모델 11434(http://121.138.151.6:11434)를 직접 부르고 있지 않은지(직접 호출 금지, 반드시 :8000 경유).
 – Content-Type 헤더(application/json)가 빠지지 않았는지.
 – 백엔드의 채팅 호출 주소·모델명이 정확한지: POST http://121.138.151.6:11434/api/chat , 모델 "qwen3.6:35b-a3b".
4) 원인을 찾으면 어디를 어떻게 고치면 되는지 한 줄로 설명하고 고쳐줘.

기대 결과(검증): 콘솔 오류의 원인(예: 백엔드 미실행/주소·모델명 오타/프론트가 11434 직접 호출)을 짚어 고친다. → **성공 기준:** 고친 뒤 같은 질문에 답변이 정상으로 뜨면 OK.

프롬프트 7 — Playwright로 자동 점검 (검증)

Playwright로 내 콜센터 챗봇을 자동 테스트해줘.

- 1) 백엔드(:8000) /health 가 응답하는지 먼저 확인.
- 2) 브라우저로 index.html 을 열기.
- 3) 챗봇 입력칸에 "주차요금 얼마야?" 입력 후 전송.
- 4) 5초 안에 답변창에 글자가 나타나고, "근거" 글자도 보이는지 확인.
- 5) 계산 질문 "A주차장 2시간이면 얼마야?"를 넣어, 답변창에 "3,000원"이 나오는지 확인(숫자 환각 점검).
- 6) 자료 밖 질문 "원장님 성함?"도 넣어, "확인되지 않습니다"가 나오는지 확인.
- 7) 모두 통과면 "통과", 아니면 "실패"로 리포트.

테스트 코드(tests/qa.spec.ts)와 실행 방법도 같이 만들어줘.
실행 전제(비개발자용, 한 번만):

- Node.js가 설치돼 있어야 한다(없으면 <https://nodejs.org>의 LTS 설치). 확인: 터미널에서 `node -v`
- 작업 디렉터리(cwd)는 index.html이 있는 프로젝트 폴더에서 실행한다.
- 설치/실행 순서: `npm init -y → npm i -D @playwright/test → npx playwright install → npx playwright test`

(테스트는 백엔드 :8000을 거쳐 검사 - 모델 11434를 직접 부르지 않음)

기대 결과(검증): 두 질문(정상/예외)이 자동으로 검사되고 통과/실패 리포트가 나온다. → **성공 기준:** 터미널에 **2 passed** (또는 **통과 리포트**)가 보이면 OK.

⚠️ 안전 수칙 (콜센터 특화)

- **환자번호·환자명·생년월일·진단명 등 개인정보 절대 금지.** 상담은 “안 내” 범위까지만.
- 자료에 **없는 내용은 지어내지 말 것** — 반드시 “확인되지 않습니다” + 담당 부서 안내.
- 의료적 진단·처방 판단은 챗봇 역할이 아님(진료 안내로 연결).
- **분리 강제:** HTML/자바스크립트에서 모델
(<http://121.138.151.6:11434> / ollama:11434)을 직접 호출 금지. 모델 호출은 오직 백엔드 <http://127.0.0.1:8000> 경유.
- 모든 데이터는 **연습용 더미** — 실제 병원 정보·모델 서버
(121.138.151.6:11434) 접속법은 외부 공유 금지.

✅ **숙제 합격선:** ① 챗봇 화면이 뜨고 ● **연결됨** ② “주차요금?”을 **자연어로 물으면** 답변창에 자료 근거 답 + 📎 출처([Q번호]) ③ “A주차장 2시간이면 얼마야?”에 **백엔드 계산값 3,000원**을 인용해 답(숫자 환각 없음) ④ 자료 밖 질문엔 “확인되지 않습니다”. 여기까지면 성공입니다.