

04. 인사 — 휴가 안내 챗봇 A RAG 챗봇

❗ 이 페이지 전제 — 복붙 전 1초 확인 (Sonnet도 그대로 동작하게 다 적었습니다) - 답변(채팅) 모델: **qwen3.6:35b-a3b** · 호출 **POST**
http://121.138.151.6:11434/api/chat (body
{ "model": "qwen3.6:35b-a3b", "messages":
[...], "stream": true } → 응답 **message.content**) - 내 백엔드: FastAPI **http://127.0.0.1:8000** — 프론트(HTML)는 반드시 이 백엔드만 부릅니다. 공통 STEP 0의 **/api/chat** (:8000) 응답은 SSE 스트림(**data:** 줄)이라, 프론트는 그 줄들을 받아 답을 이어 붙입니다. - ⚡ 금지: HTML/자바스크립트에서 **11434** · **ollama** 를 직접 호출하지 마세요(CORS·보안 사고). 모델 호출은 오직 백엔드(:8000)를 거칩니다. - 출발점: 공통 **STEP 0 기본코드**(**app.py** · **index.html**)가 떠 있는 상태에서 시작합니다(이 페이지에 코드를 다시 만들지 않음).

한 줄: 사내 휴가 규정을 근거로 휴가 종류·일수·신청절차를 답하는 안내 챗봇. **이번 주 목표:** 규정 조각을 백엔드에 넣고, 질문에 **출처(조항)**와 함께 답하기. 규정에 없으면 지어내지 말고 **“확인 불가”**.

🌟 **도달선:** 프론트(화면) → 내 백엔드(**http://127.0.0.1:8000**) → 채팅 모델 **qwen3.6:35b-a3b** (호출 **POST** **http://121.138.151.6:11434/api/chat**)이 백엔드를 통해 응답하고, “연차 며칠이야?” 한 줄에 규정 근거로 답이 나오면 성공. **검색(임베딩 bge-m3:latest)**은 다음 강의에서 — 이번 주는 **규정을 통째로 넣는 방식(컨텍스트 stuffing)**. (8조각을 통째로 넣는 이 더미는 다음 강의에서 한 줄씩 압축해 검색 대상으로 재사용합니다.)

⚡ **분리 원칙(이 과제 전체 공통):** 프론트(HTML/JS)에서 **11434** · **ollama** 를 직접 호출하지 마세요. 모델 호출은 오직 백엔드 **http://127.0.0.1:8000** 를 거칩니다(CORS·보안 사고 방지).

준비 — 공통 ①②③ 먼저

공통 핸드아웃의 ① 백엔드(app.py) → ② 프론트(index.html) → ③ 실행을 먼저 끝내세요. 화면이 뜨고 ● **연결됨** 이 보이면 아래 휴가 챗봇 프론트를 **순서대로** 엽니다.

⚠ **이 과제의 절대 원칙 3가지** 1. **규정에 있는 것만** 답한다. 없으면 **“확인 불가 — 인사팀 문의”**라고 말한다(절대 지어내지 않음). 2. **개인 휴가내역·잔여일수**는 묻지도, 입력받지도, 저장하지도 않는다. 이 앱은 **규정 안내** 전용이다. 3. 답에는 항상 근거 조항(예: **[연차]** , **[신청절차]**)을 붙인다.

휴가 규정 샘플 (이 8조각을 그대로 '참고자료' 칸에 붙여넣기)

실제 규정이 아니라 **연습용 더미**입니다. 본인 회사 실제 규정·개인정보는
넣지 마세요.

[연차]

- 입사 첫째: 1개월 만근 시마다 1일씩 발생(최대 11일).
- 1년 이상 만근: 15일. 이후 3년마다 1일씩 가산(상한 25일).
- 사용기한: 발생일로부터 1년. 미사용분은 [이월] 항목 참고.

[병가]

- 연 60일 이내 사용 가능.
- 연속 3일 이상 사용 시 의사 진단서 제출 필수.
- 입원·수술 등 장기 병가는 인사팀 사전 협의.

[반차·반반차]

- 반차: 오전(09:00~13:00) 또는 오후(13:00~18:00), 연차 0.5일 차감.
- 반반차: 2시간 단위, 연차 0.25일 차감.
- 반차·반반차도 연차에서 차감되며 잔여 연차 한도 내에서만 사용.

[경조]

- 본인 결혼: 5일.
- 자녀 결혼: 1일.
- 배우자 출산: 10일.
- 부모·배우자·자녀 사망: 5일.
- 조부모·형제자매 사망: 3일.

[공가]

- 예비군·민방위 훈련: 소집 기간만큼.
- 법정 건강검진·헌혈: 해당 일 1일.
- 법원 증인 출석 등 공적 의무: 해당 기간.

[특별휴가]

- 여름휴가: 연 3일(7~9월 중 사용, 미사용 시 소멸).
- 장기근속 포상휴가: 10년 5일 / 20년 10일.
- 난임 치료 휴가: 연 3일(최초 1일 유급).

[신청절차]

- 원칙: 휴가 시작 3일 전까지 전자결재 상신.
- 응급·부득이한 사유: 사후 24시간 이내 신청 가능.
- 경조·병가: 증빙(청첩장·사망진단서·진단서 등) 첨부.
- 결재선: 팀장 → 부서장 (3일 초과 연속 휴가는 부서장 승인 필수).

[이월·소멸]

- 미사용 연차는 다음 해로 최대 5일까지 이월.
- 이월 연차는 이월된 해 안에 우선 사용(미사용 시 소멸).
- 여름휴가·포상휴가 등 특별휴가는 이월 불가.

프롬프트 ① — 기본: 휴가 안내 챗봇으로 맞추기

복붙 프롬프트:

공통 STEP 0 기본코드(app.py·index.html)가 떠 있는 상태에서 시작한다.

공통 챗봇을 '사내 휴가 규정 안내' 전용으로 맞춰줘.

- 백엔드 app.py는 채팅 모델 `qwen3.6:35b-a3b`를 `POST http://121.138.151.6:11434/api/chat`로 호출한다(이미 STEP 0에 있으면 그대로 사용).
- 프론트(index.html)는 절대 11434/ollama를 직접 부르지 말고, 오직 내 백엔드 http://127.0.0.1:8000 로만 요청한다.
- index.html의 '참고자료' 칸 기본값으로 위 휴가 규정 8조각(연차/병가/반차/경조/공가/특별휴가/신청절차/이월)을 그대로 넣어줘.
- 시스템 프롬프트를 이렇게 바꿔줘:
"너는 사내 휴가 규정 안내 도우미다. 반드시 참고 자료에 있는 내용만으로 한국어로 간결히 답한다.
자료에 없는 내용은 추측하지 말고 '확인 불가 - 인사팀에 문의하세요'라고만 답한다.
개인의 휴가 사용내역·잔여일수는 알 수 없으므로 다루지 않는다."
- 화면 제목을 "휴가 안내 챗봇"으로 바꾸고, 입력창 안내문구를 "예: 연차 며칠이야? / 경조 휴가 종류는?"으로.

기대 결과: “연차 며칠이야?”에 규정 근거로 “1년 이상 만근 시 15일…”이라고 답한다.  **성공 확인:** 화면 제목이 “휴가 안내 챗봇”으로 바뀌고, “연차 며칠이야?” 전송 시 답에 “15일”이 보이면 성공. (터미널에 채팅 모델 `qwen3.6:35b-a3b` 호출 로그가 한 번 찍힘.)

프롬프트 ② — 출처(조항) 표시

복붙 프롬프트:

답변할 때 어느 항목을 근거로 했는지 '출처'를 함께 보여줘.

- 시스템 프롬프트에 규칙 추가: "답변 맨 끝에 줄을 바꿔, 근거가 된 항목명을 대괄호로 표기한다.
예: 출처: [연차], [신청절차]. 자료에 없으면 출처를 표기하지 않고 '확인 불가'라고 한다."
- index.html에서 답변 영역 아래쪽에 출처 줄을 작은 회색 글씨로 구분해서 보이게 해줘(프론트는 백엔드 http://127.0.0.1:8000 응답만 사용, 11434/ollama 직접 호출 금지).

기대 결과: “병가 진단서 필요해?” → 답 끝에 출처: [병가] 가 작게 붙는다. “휴가 신청 언제까지?” → 답 끝에 출처: [신청절차], “여름휴가 며칠?” → 출처: [특별휴가] 처럼 근거 항목명이 함께 표기된다.  **성공 확인:** 답변 마지막 줄에 회색으로 출처: [병가] 가 보이고, “휴가 신청 언제까지?”엔 출처: [신청절차] 가 보이면 성공.

프롬프트 ③ — 없는 규정은 “확인 불가” 처리

복붙 프롬프트:

규정에 없는 질문에 모델이 그럴듯하게 지어내지 않도록 강하게 막아 줘.

- 시스템 프롬프트에 규칙 추가:

"다음은 반드시 지킨다. (1) 자료에 명시되지 않은 일수·금액·조건은 절대 만들어내지 않는다.

(2) 자료로 답할 수 없으면 정확히 '확인 불가 - 인사팀에 문의하세요'라고만 답한다.

(3) 개인 휴가내역·잔여일수를 묻는 질문에는 '개인 휴가내역은 이 챗봇에서 확인할 수 없습니다'라고 답한다."

- 테스트로 "내 남은 연차 며칠이야?", "안식년 며칠이야?" 두 질문을 넣었을 때 위 규칙대로 답하는지 확인해줘.

기대 결과: "안식년 며칠?" → 지어내지 않고 "확인 불가 - 인사팀에 문의하세요". "내 남은 연차?" → 개인내역 안내 멘트. **✅ 성공 확인:** "안식년 며칠이야?" 답에 "확인 불가"가, "내 남은 연차 며칠이야?" 답에 "개인 휴가내역"이 들어가 있으면 성공.

프롬프트 ④ - 집계 질문은 백엔드가 '계산값'을 만들어 근거로 넘긴다 (환각 방지)

💡 **왜 따로 두나:** "경조 휴가 중 가장 긴 건?", "본인 결혼 + 배우자 출산 합치면 며칠?" 같은 **숫자 비교·합산** 질문은, 규정 텍스트만 통째로 넘기면 모델이 종종 **합·최댓값을 틀리게 지어냅니다**. 그래서 **계산은 백엔드 파이썬 코드로 정확히** 해서 그 결과값을 컨텍스트(근거)로 넘기고, **모델은 그 값을 인용만** 하게 합니다. 도달 화면은 그대로 챗봇(질문창+답변창+출처)입니다 - 계산만 코드로, 표현은 대화로.

복붙 프롬프트:

숫자 집계·비교 질문에서 모델이 숫자를 지어내지 않게, 백엔드가 먼저 정확히 계산하고 그 값을 근거로 넘기게 해줘.

- app.py에 경조 일수를 코드 안 디렉터리로 둔다(규정 더미 그대로):

```
LEAVE_DAYS = {"본인 결혼":5, "자녀 결혼":1, "배우자 출산":10, "부모·배우자·자녀 사망":5, "조부모·형제자매 사망":3}
```

- 질문이 '가장 긴/짧은', '합치면/합계', 'A와 B 중 며칠 차이' 같은 집계 의도면(간단 키워드 매칭으로 판별),

백엔드가 LEAVE_DAYS로 직접 계산해 결과 문자열을 만든다.

예) 최댓값 → "계산결과: 경조 중 최장은 [배우자 출산] 10일"

합산 → "계산결과: 본인 결혼 5일 + 배우자 출산 10일 = 15일"

- 이 '계산결과:' 문장을 시스템 컨텍스트(참고자료)에 한 줄 더 끼워 모델에 넘기고, 시스템 프롬프트에 규칙 추가:

"참고자료에 '계산결과:' 줄이 있으면, 숫자는 반드시 그 값을 그대로 인용해 답한다. 직접 더하거나 추측하지 않는다."

- 집계 의도가 아니면 기존처럼 평범하게 답한다. 출처는 [경조]로 붙인다.

- 계산·모델 호출은 모두 백엔드에서. 프론트는 백엔드

http://127.0.0.1:8000 만 부른다(11434/ollama 직접 호출 금지).

기대 결과(결정론적 정답): “경조 중 가장 긴 휴가는?” → “[배우자 출산] 10일”(코드가 max로 계산한 10일을 모델이 인용). “본인 결혼이랑 배우자 출산 합치면?” → “15일”(5+10, 코드 합산값 인용). 모델이 12일·14일 같은 엉뚱한 합을 내지 않는다.  **성공 확인:** “경조 중 가장 긴 휴가 며칠이야?” 답에 “10일”과 출처: [경조] 가 보이고, 터미널에 백엔드가 만든 계산결과: ... 10일 로그가 찍히면 성공. (값을 코드가 만들었으므로 매번 같은 정답이 나옴.)

프롬프트 ⑤ — 디버깅: 답이 이상할 때

복붙 프롬프트:

다음 중 내 앱에서 일어나는 증상을 찾아 원인과 해결을 알려주고 코드를 고쳐줘:

- 증상A: 화면에 "백엔드 꺼짐"으로 표시되고 답이 안 나온다.
- 증상B: 답은 나오는데 출처가 안 보인다.
- 증상C: 규정에 없는 걸 물어도 그럴듯하게 지어낸다.
- 증상D: "합치면 며칠?" 같은 집계 질문에 합·최댓값을 틀리게 답한다(예: 5+10인데 14일이라고 함).

각 증상별로 (원인 → 어디를 보면 되는지 → 수정안)을 한국어로 정리하고, 필요한 부분만 고쳐줘.

(힌트: A는 uvicorn 실행/포트 8000 + 채팅 모델 `qwen3.6:35b-a3b` 호출 주소 `http://121.138.151.6:11434/api/chat` 확인, B는 출처 표시 코드, C는 시스템 프롬프트 규칙, D는 프롬프트 ④의 백엔드 계산값(LEAVE_DAYS·'계산결과:' 줄)이 컨텍스트에 들어갔는지 확인)

- 어떤 경우에도 프론트(HTML/JS)에서 11434/ollama를 직접 부르도록 고치지 말 것. 호출은 오직 백엔드 http://127.0.0.1:8000 경유.

기대 결과: 세 증상의 원인·수정 위치가 정리되고, 막혔던 증상이 풀린다.

 **성공 확인:** 내 증상에 해당하는 답이 다시 정상 출력되면 성공(예: A 해결 후 화면 상단이  연결됨 으로 바뀜).

프롬프트 ⑥ — 기능 추가: 경조 종류 빠른버튼

복붙 프롬프트:

자주 묻는 항목을 버튼으로 만들어줘.

- index.html 입력창 위에 빠른버튼 6개를 추가(왼쪽부터 1~6번 순서): [본인 결혼] (1·출처[경조]) [배우자 출산] (2·출처[경조]) [부모 사망] (3·출처[경조]) [병가] (4·출처[병가]) [반차] (5·출처[반차·반반차]) [신청절차] (6·출처[신청절차]).
- 버튼을 누르면 해당 질문이 입력창에 자동으로 채워지고 바로 전송돼서 답이 뜨게.
- 버튼은 작고 둥근 스타일로, 모바일에서도 잘보이며 잘 보이게.
- 데이터·규정은 절대 버튼 코드에 박지 말고(질문 텍스트만 채움), 호출은 오직 백엔드 http://127.0.0.1:8000 경유. 프론트에서 11434/ollama 직접 호출 금지.

🔥 **버튼 구성 안내:** 이번 숙제 버튼은 왼쪽부터 6개이고, **5번째가 [반차]** 입니다(6번째는 **[신청절차]**). 다음 강의에서는 검색(임베딩) 대상 다양화를 위해 이 **5번째 [반차]** 를 **[여름휴가]** 로 같은 자리에서 교체해 씁니다(나머지 5개는 동일) — 헛갈리지 마세요.

기대 결과: [배우자 출산] 버튼 클릭 → 자동으로 질문 전송되고 “10일” 답이 출력와 함께 뜬다. ✅ **성공 확인:** 입력창 위에 둥근 버튼 6개가 보이고, [배우자 출산] 클릭 시 자동 전송되어 답에 “10일” + 출처: **[경조]** 가 뜨면 성공.

프롬프트 ⑦ — 검증: Playwright 자동 QA

복붙 프롬프트:

```
Playwright로 내 휴가 챗봇을 자동 테스트해줘.
0) 먼저 app.py에 `GET /health` 엔드포인트가 있는지 확인하고, 없으면 `{ "ok": true }`를 200으로 반환하는
`@app.get("/health")`를 추가해줘(아래 1단계가 이걸 호출함).
1) 백엔드 http://127.0.0.1:8000/health 연결 먼저 확인.
2) 브라우저로 index.html 열기.
3) 질문 입력칸에 "본인 결혼 휴가 며칠이야?" 입력 후 전송.
4) 8초 안에 답변에 "5일"이 포함되고, 출처에 "[경조]"가 보이는지 확인.
5) 이어서 "안식년 며칠이야?" 입력 → 답에 "확인 불가"가 포함되는지 확인.
6) 집계 검증: "경조 중 가장 긴 휴가 며칠이야?" 입력 → 답에 "10일"이 포함되는지 확인(백엔드 계산값 인용 확인).
7) 셋 다 통과하면 "통과", 아니면 어떤 단계에서 실패했는지 리포트.
- 테스트는 화면(프론트)을 통해서만 조작하고, ollama(11434)를 직접 부르지 않는다(실제 모델 호출은 백엔드 :8000 경유).
테스트 코드(tests/qa.spec.ts)와 실행 방법도 같이 만들어줘.
```

기대 결과: “본인 결혼=5일+[경조]” 통과, “안식년=확인 불가” 통과, “경조 최장=10일”(백엔드 계산값) 통과 → 콘솔에 “통과” 리포트. ✅ **성공 확인:** 터미널/콘솔 마지막 줄에 “통과”가 출력되면 성공. (`/health` 가 404면 0 단계 지시대로 엔드포인트부터 추가.)

설치 주의: 처음 1회 **`npx playwright install`** (브라우저 다운로드), Node 18+, 백엔드·모델이 먼저 떠 있어야 함. 어려우면 다음 강의에서 함께.

안전수칙 (필독)

- **개인 휴가내역·잔여일수 입력/저장 금지** — 이 앱은 *규정 안내* 전용. “내 휴가 며칠 남았어”는 안내 대상이 아님.
- **실제 사내 규정·개인정보 입력 금지** — 숙제는 위 더미 8조각으로만.

- 규정에 없으면 반드시 “확인 불가” — 지어낸 일수는 사고로 이어짐.
- 모델 답은 참고용 — 실제 신청·승인은 인사팀·결재선 확인.