

08. 간호부 — 간호 임상지원 챗봇 A RAG 챗봇

❗ 이 페이지 전제 — 복붙 전 1초 확인 (Sonnet도 그대로 동작하게 다 적었습니다) - 답변(채팅) 모델: **qwen3.6:35b-a3b** · 호출 **POST**
http://121.138.151.6:11434/api/chat - (참고) 검색(임베딩) 모델 **bge-m3:latest** 은 다음 강의용 — 이번 숙제에서는 쓰지 않습니다(자료를 통째로 모델에 넘김). - 내 백엔드: FastAPI
http://127.0.0.1:8000 — 프론트(HTML)는 반드시 이 백엔드만 부릅니다. - ⚡ 금지: HTML/자바스크립트에서 **11434** · **ollama** 를 직접 호출하지 마세요(CORS·보안 사고). 모델 호출은 오직 백엔드 (:8000)를 거칩니다. - 출발점: 공통 **STEP 0 기본코드** (**app.py** · **index.html**)가 떠 있는 상태에서 시작합니다(이 페이지에 코드를 다시 만들지 않음). STEP 0 **/api/chat** 은 SSE 스트림 (**data:** 라인)으로 응답합니다.

⚠ 대외비 — 더미만 사용: 실제 간호 프로토콜은 대외비(부서·과제 내부 자료)입니다. 이 앱은 원격 모델(**qwen3.6:35b-a3b** @ **http://121.138.151.6:11434/api/chat**)을 호출하므로, 실제 자료를 넣으면 외부로 나갑니다. 숙제는 이 페이지의 더미(가짜) 샘플로만 연습하세요. 환자 식별정보(이름·등록번호·생년월일 등) 입력 금지. 실제 자료는 다음 강의(내부망)에서 다룹니다.

한 줄 목표: 자연어로 묻고 더미 자료 근거로 답하는 챗봇 1개. 최종 화면은 질문 입력창 + 답변창(+출처 표시)입니다. 표·버튼은 보조일 뿐, 핵심은 “EGD 금식 얼마나?”, “수혈하다 발열나면?”처럼 그냥 말로 물으면 더미 자료를 근거로 답하고 출처를 같이 보여주는 대화입니다.

이번 주 방식(임베딩 없음 = stuffing): 더미 8조각을 통째로 컨텍스트에 넣어 모델이 그 안에서 답을 찾게 합니다(검색·임베딩은 다음 강의). 검사·시술명을 물으면 목적 / 검사 전 간호 / 검사 후 간호 / 주의사항으로 정리하고, 어느 조각을 근거로 했는지 출처를 답변 아래에 답니다.

이번 주 도달선: 백엔드(:8000)와 프론트(index.html)가 각각 뜨고, 채팅창에 자연어 질문을 넣으면 자료 근거로 정리된 답 + 출처가 나오면 성공.

0. 출발 전 — 공통 STEP 0 기본코드부터

공통 STEP 0 기본코드(**app.py** · **index.html**)가 떠 있어야 합니다. 즉 ① 백엔드 FastAPI **http://127.0.0.1:8000** 실행, ② 프론트 **index.html** 표시, ③ 헬스체크 **GET** **http://127.0.0.1:8000/health** 가 **ok** — 이 세 가지가 된 상태에서 출발하세요. (이 페이지에 **app.py** · **index.html** 전체 코드를 다시 만들지 않습니다. 공통 STEP 0 코드를 그대로 참조합니다.)

아래 프롬프트들은 그 위에 있습니다. 모델 호출은 모두 백엔드(:8000)를 거쳐 채팅 모델 `qwen3.6:35b-a3b` (`POST http://121.138.151.6:11434/api/chat`)로 갑니다. HTML에서 `11434` · `ollama` 를 직접 부르지 마세요.

✅ **출발 성공 기준:** 브라우저에 공통 `index.html` 채팅창이 보이고, 터미널에서 `curl http://127.0.0.1:8000/health` 가 `{"status":"ok"}` (또는 `ok`)를 반환하면 출발 준비 완료.

더미 검사 샘플 (8조각) — 복붙용

아래는 전부 가짜 예시입니다. 교육용 일반 상식 수준이며, 실제 병원 프로토콜이 아닙니다. 그대로 복붙해서 쓰세요. **개수 확인: 정확히 8건**(1) EGD · 2) 대장내시경 · 3) 수혈 · 4) 조영 CT · 5) MRI · 6) 채혈 · 7) 심전도 · 8) 복부 초음파). 뒤의 빠른검색 버튼·검색 칩도 이 8건과 1:1로 맞춰야 합니다.

[검사·시술 전후 간호 - 더미 예시 8건 / 교육용 / 실제 프로토콜 아님]

1) EGD(위내시경)

- 목적: 식도·위·십이지장 점막을 직접 관찰
- 검사 전 간호: 8시간 금식, 의치·안경 제거, 동의서 확인
- 검사 후 간호: 2시간 금식(수면내시경은 각성 후), 인후통 정상 안내
- 주의사항: 검사 후 복통·흑색변·발열 시 즉시 보고

2) 대장내시경

- 목적: 대장 점막·용종 관찰 및 제거
- 검사 전 간호: 전날 저잔사식, 장정결제 복용, 맑은 변 확인
- 검사 후 간호: 가스 배출 격려, 용종절제 시 당일 자극적 음식 제한
- 주의사항: 절제 후 출혈·심한 복통·발열 시 즉시 보고

3) 수혈

- 목적: 부족한 혈액성분 보충
- 검사 전 간호: 환자·혈액 이중 확인, 활력징후 측정, 동의서 확인
- 검사 후 간호: 시작 15분 집중관찰, 종료 후 활력징후 재측정
- 주의사항: 발열·오한·발진·호흡곤란 시 즉시 중단·보고

4) 조영 CT

- 목적: 조영제로 혈관·장기 병변 대조 관찰
- 검사 전 간호: 신기능(eGFR) 확인, 조영제 알레르기 문진, 4시간 금식
- 검사 후 간호: 수분 섭취 격려(조영제 배출), 천자부위 관찰
- 주의사항: 두드러기·호흡곤란 등 지연성 알레르기 반응 안내

5) MRI

- 목적: 강한 자기장으로 연부조직 정밀 영상
- 검사 전 간호: 체내 금속·인공물 확인, 금속류 제거, 폐소공포 확인
- 검사 후 간호: 특이사항 없으면 일상 복귀, 진정 시 각성 관찰
- 주의사항: 심박동기·금속 이식물 있으면 검사 금기 가능 - 반드시 사전 확인

6) 채혈(정맥)

- 목적: 혈액검사용 검체 채취
- 검사 전 간호: 검사별 금식 여부 확인, 환자 확인
- 검사 후 간호: 천자부위 2~5분 압박지혈, 멍 안내
- 주의사항: 지속 출혈·어지럼 시 보고, 같은 팔 반복 천자 주의

7) 심전도(ECG)

- 목적: 심장 전기활동 기록으로 부정맥·허혈 평가
- 검사 전 간호: 안정 후 측정, 전극 부착부위 노출
- 검사 후 간호: 전극 제거, 피부 자극 확인
- 주의사항: 검사 중 움직임·말하기 자제(파형 왜곡)

8) 복부 초음파

- 목적: 간·담낭·췌장 등 복부 장기 관찰
- 검사 전 간호: 6~8시간 금식(담낭 수축 방지)
- 검사 후 간호: 특이사항 없으면 즉시 식사 가능
- 주의사항: 가스 많으면 영상 제한 - 재검 가능 안내

프롬프트 1 — 기본 간호 챗봇으로 맞추기

공통 STEP 0 기본코드(app.py·index.html)로 만든 챗봇을 '간호 임상지원' 용으로 바꿔줘.

- 채팅 호출은 백엔드 app.py에서 POST `http://121.138.151.6:11434/api/chat` , 모델 "qwen3.6:35b-a3b" 로 한다.
(index.html은 절대 121.138.151.6:11434/ollama를 직접 부르지 말고, 항상 `http://127.0.0.1:8000` 백엔드만 호출한다.)
- index.html의 '참고자료' 칸 기본값으로 위 더미 검사 샘플 8건을 그대로 넣어줘.
- 검사·시술명을 물으면 반드시 '목적 / 검사 전 간호 / 검사 후 간호 / 주의사항' 순서로 답하게 시스템 프롬프트를 바꿔줘.
- 참고자료에 없는 검사를 물으면 지어내지 말고 "제공된 더미 자료에서 확인되지 않습니다"라고 답해.
- 화면 상단에 빨간 경고띠로 "대외비 자료·환자 식별정보 입력 금지 (더미 전용)"을 항상 표시해줘.

기대 결과: “EGD 금식 얼마나?” 물으면 목적·전·후·주의 4섹션으로 정리된 답이 나온다.  **성공 확인:** 화면 상단에 빨간 경고띠가 보이고, “EGD 금식 얼마나?” 전송 시 4개 소제목(목적/검사 전 간호/검사 후 간호/주의사항)이 모두 들어간 답이 채팅창에 뜨면 성공. (브라우저 개발자도구 Network 탭에서 요청이 `127.0.0.1:8000` 으로부터 `121.138.151.6:11434` 로 직접 가지 않으면 분리 정상.)

프롬프트 2 — 답변을 섹션 카드로 구조화

답변을 보기 좋게 구조화해줘.

- 채팅 호출은 그대로 백엔드 app.py → POST `http://121.138.151.6:11434/api/chat` , 모델 "qwen3.6:35b-a3b" 경유로 유지한다. (index.html에서 11434/ollama 직접 호출 금지, 호출은 오직 백엔드 `http://127.0.0.1:8000` 경유.)
- 모델이 답할 때 '목적 / 검사 전 간호 / 검사 후 간호 / 주의사항' 4개 소제목을 굵게 달도록 시스템 프롬프트에 예시 형식을 넣어줘.
- index.html에서는 그 4개 소제목을 각각 카드(박스)로 나눠 보여줘. '주의사항' 카드만 열린 빨강 배경으로.
- 검사명이 없는 일반 질문이면 카드 없이 한 단락으로만 답해.

기대 결과: “대장내시경 알려줘” → 4개 색 카드로 깔끔하게 분리되어 보인다.  **성공 확인:** “대장내시경 알려줘” 전송 시 4개 카드가 보이고 '주의사항' 카드만 열린 빨강 배경이면 성공.

프롬프트 3 — 출처(근거 조각) 표시

답변 아래에 '근거' 줄을 추가해줘.

- 채팅 호출은 그대로 백엔드 app.py → POST
http://121.138.151.6:11434/api/chat , 모델
"qwen3.6:35b-a3b" 경유. (index.html에서 11434/ollama
직접 호출 금지, 호출은 오직 백엔드 http://127.0.0.1:8000
경유.)
- 모델이 참고한 더미 샘플의 '번호·검사명'(예: 3) 수혈)을 답변
끝에 [근거: 3) 수혈] 형태로 함께 출력하게 해줘.
- index.html에서는 그 [근거: ...] 부분을 답변 본문과 분리해
작은 회색 글씨로 아래에 표시해줘.
- 자료에 없어서 "확인되지 않습니다"라고 답할 때는 근거 줄을 비워
둬.

기대 결과: 답 끝에 “근거: 4) 조영 CT”처럼 어느 조각을 봤는지 표시된다.

✅ **성공 확인:** “조영CT 전 뭐 확인해?” 전송 시 본문 아래 작은 회색 글씨로 “근거: 4) 조영 CT”가 보이면 성공. 자료에 없는 검사를 물으면 근거 줄이 비어 있으면 성공.

프롬프트 4 — 집계·정확대조 질문 (숫자는 코드가 계산, 답은 챗봇이 인용)

챗봇에 “금식 시간이 가장 긴 검사는?”처럼 **숫자 비교·집계** 질문을 하면, 모델이 숫자를 지어낼(환각) 위험이 있습니다. 그래서 **계산은 백엔드 코드가 정확히 하고, 그 결과값을 컨텍스트(근거)로 모델에 넘겨** 모델이 그 값을 인용해 자연어로 답하게 합니다.

챗봇이 '금식 시간 비교' 같은 집계 질문에 정확히 답하게 해줘. (모든 모델 호출은 백엔드 app.py 경유 POST
http://121.138.151.6:11434/api/chat , 모델
"qwen3.6:35b-a3b". index.html은 11434/ollama 직접 호출 금지, 호출은 오직 백엔드 http://127.0.0.1:8000 경유.)

- app.py 안에 더미 8건의 '검사 전 금식시간'을 코드로 둔 표(딕셔너리)를 만들어줘:
EGD=8시간, 대장내시경=0시간(저장사식·장정결제), 수혈=0시간, 조영CT=4시간, MRI=0시간, 채혈=검사별(0~8시간, '검사에 따라 다름'), 심전도=0시간, 복부초음파=6~8시간.
- 질문에 '가장 길', '가장 짧', '비교', '몇 시간', '제일' 같은 말이 들어오면 → 백엔드가 위 표를 코드로 정렬·비교해 '정답값'을 먼저 구한다(예: 최대 금식 = EGD 8시간).
- 그 정답값을 한 줄 근거 문장으로 만들어(" [집계결과] 금식시간 최대: EGD 8시간, 최소: 0시간(대장내시경/수혈/MRI/심전도)") 모델 컨텍스트에 같이 넣고, "이 [집계결과] 숫자만 인용해서 답하고 숫자를 새로 만들지 마"라고 시스템 프롬프트에 지시한다.
- 답변 아래 출처는 [근거: 집계결과(금식시간 표)]로 표시한다.
- 표에 없는 항목을 묻거나 계산 불가하면 "자료로 계산할 수 없습니다"라고 답해.

기대 결과(결정론적 정답): “금식 제일 오래 하는 검사?” → “EGD(위내시경), 8시간” 으로 항상 동일하게 답한다(모델이 다른 숫자를 지어내지 않음). “금식 안 하는 검사?” → 대장내시경·수혈·MRI·심전도(0시간). **✅ 성공 확인:** “금식 제일 오래 하는 검사?”를 3번 보내도 매번 “EGD 8시간”이 나오고, 답 아래 “근거: 집계결과(금식시간 표)”가 보이면 성공. (백엔드 로그에 정렬·비교 결과 한 줄이 찍히면 계산이 코드에서 일어난 것.)

프롬프트 5 — 빠른 검색 버튼 (보조 입력 도우미)

챗봇이 핵심이고, 아래 버튼은 **질문창에 자연어 질문을 대신 넣어주는 보조 도우미**일 뿐입니다(버튼이 답을 직접 만들지 않음).

검사명을 매번 타이핑하지 않게, 자주 쓰는 검사 8개를 버튼으로 만들어줘.

- index.html 질문창 위에 칩(버튼) 정확히 8개: EGD / 대장내시경 / 수혈 / 조영CT / MRI / 채혈 / 심전도 / 복부초음파 (위 더미 8건과 1:1).
- 버튼을 누르면 질문창에 "○○ 검사 전후 간호 알려줘"가 자동 입력되고, 평소처럼 챗봇 전송 흐름을 그대로 탄다(버튼은 입력만 채울 뿐 별도 경로 없음).
- 전송은 기존과 동일하게 백엔드 `http://127.0.0.1:8000` 경유로만 보낸다(채팅 모델 `qwen3.6:35b-a3b @ http://121.138.151.6:11434/api/chat`). HTML에서 `11434/ollama` 직접 호출 금지.
- 모바일에서도 버튼이 잘바꿈되며 잘 보이게 해줘.

기대 결과: “수혈” 버튼 한 번 누르면 질문창이 채워지고, 챗봇이 수혈 전후 간호를 출처와 함께 답한다. **✅ 성공 확인:** 칩 8개가 한 줄에 안 들어가면 잘바꿈되어 모두 보이고, ‘수혈’ 칩을 누르면 질문창에 “수혈 검사 전후 간호 알려줘”가 자동 입력·전송되어 출처 포함 답이 뜨면 성공.

프롬프트 6 — 안전장치 (환자정보 차단)

환자 식별정보가 들어가면 막아줘.

- index.html에서 질문이나 참고자료 칸에 숫자 6자리 이상 연속 (등록번호·주민번호 앞자리 등 식별번호 의심이라 6자리부터 차단)이나 ‘환자명/주민번호’ 같은 단어가 있으면, 전송을 막고 “환자 식별정보는 입력할 수 없습니다 (더미만)”라고 빨간 경고를 띄워줘.
- 백엔드 `app.py`에서도 같은 패턴(정규식 `\d{6,}`)이 들어오면 400 에러로 거부하고 로그에 남겨줘. (이 검사는 백엔드에서 일어나며, 모델 호출 `qwen3.6:35b-a3b @ http://121.138.151.6:11434/api/chat` 전에 막는다. index.html은 `11434/ollama` 직접 호출 금지, 호출은 오직 백엔드 `http://127.0.0.1:8000` 경유.)
- 정상 질문은 그대로 통과.

기대 결과: “환자 정경○○ 12345678 수혈” 입력 → 전송이 막히고 경고가 뜬다. **✅ 성공 확인:** 위 입력 시 빨간 경고가 뜨고 전송이 안 되며, “수혈 전후 간호 알려줘”(식별정보 없음)는 정상 통과해 답이 뜨면 성공.

프롬프트 7 — 디버깅 (안 될 때 복붙)

지금 내 앱이 동작하지 않아. 아래를 순서대로 점검하고 고쳐줘.

- 1) 백엔드가 떠 있나: GET `http://127.0.0.1:8000/health` 가 ok 인지 확인
- 2) 프론트(index.html)가 ollama(11434)를 직접 부르고 있지 않은지 확인 — 호출은 오직 백엔드 `http://127.0.0.1:8000` 경유여야 한다. 직접 호출 코드가 있으면 백엔드 경유로 고쳐.
- 3) 백엔드가 채팅 모델을 제대로 부르는지: POST `http://121.138.151.6:11434/api/chat` , 모델 "qwen3.6:35b-a3b" 로 요청이 나가는지 확인.
- 4) 답이 한 글자도 안 나오면 SSE 파싱(STEP0 /api/chat 은 SSE 스트림 — `data:` 라인을 줄 단위로 파싱, `\n\n` 구분) · CORS 설정 확인
- 5) "확인되지 않습니다"만 계속 나오면 참고자료 칸(컨텍스트)에 더미 8건이 통째로 들어갔는지 확인(이번 주는 stuffing 방식이라 8조각이 매번 컨텍스트에 들어가야 함)
- 6) 집계 질문(금식 제일 긴 검사 등)에 숫자가 들쭉날쭉하면, 백엔드가 먼저 코드로 계산한 [집계결과] 값을 컨텍스트에 넣고 있는지 확인 (모델이 직접 계산하면 환각 발생)

각 단계에서 무엇이 문제였고 어떻게 고쳤는지 한 줄씩 알려줘.

기대 결과: 막힌 원인을 단계별로 짚어 고쳐 준다.  **성공 확인:** 위 점검 후 "EGD 금식 얼마나?"가 4섹션 답으로 정상 출력되면 성공.

마무리 체크 & 안전

-  백엔드/프론트 따로 뚫 →  자연어 질문에 자료 근거 답(4섹션) →  출처 표시 →  집계 질문은 코드 계산값 인용(EGD 8시간) →  빠른검색 버튼 8개 →  환자정보 차단.
-  **핵심은 챗봇 대화:** 표·버튼이 아니라 "자연어로 묻고 자료 근거로 답 + 출처"가 도달선. 집계·비교 숫자는 백엔드 코드가 계산한 값을 모델이 인용(환각 방지).
-  **분리 확인:** index.html이 11434 · ollama 를 직접 부르지 않고, 모든 모델 호출이 백엔드 `http://127.0.0.1:8000` 경유다(브라우저 Network 탭에 121.138.151.6:11434 직접요청이 없으면 정상).
- **대외비 자료를 외부 모델(qwen3.6:35b-a3b @ `http://121.138.151.6:11434`)로 절대 전송 금지** — 속제는 더미 8건만.
- **환자 식별정보 입력 금지.** 모델 답은 참고용 — 실제 적용은 간호 프로토콜·담당자 확인.
- 막히면 다음 강의에서 함께 봅니다. 여기까지 뜨면 속제 성공.