

공유 AI 서버(게이트웨이) · API 사용 안내

삼성창원병원 AI 업무지원 교육 — 우리 공유 AI 게이트웨이를 내 코드에서 호출하는 방법

 온프레미스 처리. 추론은 원내 spark-2 서버에서 수행됩니다. 인증 (API Key) 없이 호출하니, 환자정보·대외비 자료는 입력하지 마세요(더미·비식별만).

 이번부터 달라진 점: 각자 모델 주소를 외우거나 **think · num_predict** 같은 옵션을 신경 쓸 필요가 없습니다. 공유 게이트웨이가 추론 토큰 차단·출력 상한·모델명 보정을 **자동으로** 해줍니다. 여러분은 **주소 한 줄만** 게이트웨이로 바꾸면 됩니다.

1. 접속 주소

방법	주소	연제
① 게이트웨이(권장·기본)	http://121.138.151.6:11500	어디서나 — 형식이 겹치므로
(참고) 업스트림 직결	http://121.138.151.6:11434	게이트웨이 정보 없음

방법	주소	언제 음 — 비 권 정

게이트웨이(:11500)를 쓰면 아래 “자동 보정” 덕분에 답변창에 생각이 새거나 답이 빈 채로 오는 일이 없습니다. 직결(:11434)은 보정이 없어 추론 토큰 누출·빈 답 문제가 그대로 나타납니다. 특별한 이유가 없으면 쓰지 마세요.

2. 게이트웨이가 자동으로 해주는 것 (= 여러분이 신경 안 써도 되는 것)

보정	내용
추론 토큰 차단	qwen3.6 계열에 <code>think:false</code> 자동 주입 + 응답의 <code>thinking</code> ·인라인 <code><think>...</think></code> 제거 → 답변창에 사고과정이 새지 않음
출력 상한	<code>num_predict</code> 기본 512 상한 주입 → 폭주·서버 부하 억제
모델명 정규화	서빙 목록에 없는 모델명은 기본 채팅모델로 매핑 → 모델명 오타에도 동작
CORS 허용	브라우저에서 직접 호출도 가능

그래서 예전에 안내했던 `"think": false` 를 이제 안 넣어도 됩니다(넣어도 무해). 게이트웨이가 알아서 처리합니다.

3. 사용할 모델

용도	모델 이름	비고
채팅(생성)	qwen3.6:35b-a3b	35B MoE · 한국어 우수 (게이트웨이가 추

용도	모델 이름	비고
		론 자동 차단)
임베딩(검색용 벡터)	bge-m3:latest	다국어 · 1024차원

전체 목록 확인: `curl`

`http://121.138.151.6:11500/api/tags` hira처럼

`qwen2.5:14b-instruct-q4_K_M` 를 쓰던 앱도 그대로 호출됩니다(서빙 중).

4. 호출 방법 (예제)

(1) 채팅 — 터미널(curl)

```
curl http://121.138.151.6:11500/api/chat -d '{
  "model": "qwen3.6:35b-a3b",
  "messages": [
    { "role": "user", "content": "외래 진료시간을 안내
      해줘" }
  ],
  "stream": false
}'
```

응답의 `message.content` 에 답변이 들어 있습니다.

(`think` · `num_predict` 를 안 보내도 게이트웨이가 처리합니다.)

(2) 채팅 — Python

```
import requests

res =
    requests.post("http://121.138.151.6:11500
    /api/chat", json={
        "model": "qwen3.6:35b-a3b",
        "messages": [{"role": "user", "content": "안녕
        하세요, 한 문장으로 인사해줘"}],
        "stream": False,
    })
print(res.json()["message"]["content"])
```

`stream: True` 로 호출하면 응답이 NDJSON(한 줄에 한 JSON)으로 옵니다: `{"message":{"content":"토`
`큰"},"done":false}` ... 마지막 `{"done":true}` . 화면에 한
 글자씩 흘러려면 stream을 켜세요.

(3) 임베딩(검색·RAG용)

```
curl http://121.138.151.6:11500/api/embeddings -d
'{
  "model": "bge-m3:latest",
  "prompt": "환자 안내문 한 문장"
}'
```

응답의 **embedding** 이 숫자 벡터(1024개, 검색에 사용). 여러 문장을 한 번에 임베딩하려면 **/api/embed** 에 **{"input": ["문장1", "문장2"]}** 로 보내면 **embeddings** 배열이 옵니다.

(4) 내 앱 주소 바꾸기 (핵심)

기존 코드에서 모델 주소만 게이트웨이로 바꾸면 끝입니다.

```
- OLLAMA_URL = "http://121.138.151.6:11434"
+ OLLAMA_URL = "http://121.138.151.6:11500"
```

바꾼 뒤엔 **think** / **num_predict** 관련 코드를 따로 손볼 필요가 없습니다(게이트웨이가 처리).

5. 안전 수칙 (필독)

- 환자정보 · 대외비 자료 입력 금지 — 더미·비식별 데이터만 사용하세요.
- 인증이 없는 공유 서버입니다 — 대용량·반복 호출은 자제(다른 수강생과 GPU 공유).
- 추론은 spark-2에서 수행됩니다. 단, **입력 데이터는 본인이 책임집니다**.
- 주소·접속법은 **외부에 공유하지 마세요**(내부 교육 자료).

부록 · 빠른 점검

```
# 게이트웨이 상태(살아있는지·업스트림 연결)
curl http://121.138.151.6:11500/health

# 버전 / 모델 목록
curl http://121.138.151.6:11500/api/version
curl http://121.138.151.6:11500/api/tags
```

문의: 정보지원팀 · 강의 진행자