

02. 콜센터 — 콜센터 안내 챗봇

4주차 한 줄 목표: 내 앱의 모델 주소를 공유 게이트웨이(:11500)로 맞추면, 생각 누출·부하·모델명 같은 운영 문제를 게이트웨이가 대신 처리해 준다. 이 앱은 이미 그 주소로 설정되어 있어, 오늘은 “제대로 붙어 있는지 확인”이 핵심입니다.

1. 내 앱 한눈에

- **아키타입**: A형 — RAG(검색 기반 안내) 챗봇. 병원 이용안내 8개 주제(외래시간·주차·면회·증명서·접수수납·진료과위치·휴진·기타)를 임베딩으로 검색(상위 2개)한 뒤, LLM이 **검색된 자료에만 근거해** 답하는 구조입니다.
- **핵심 기능 3가지**:
 1. **주차요금 자동 계산** — 질문에서 시간/분을 뽑아 코드로 정확히 산출한 뒤 **[계산결과]** 로 모델에 넣어줍니다(환각 방지). 예: A주차장 2시간 = 4,000원.
 2. **개인정보 즉시 차단** — 주민번호·환자번호 같은 패턴이 들어오면 **모델을 부르지도 않고** 바로 차단 응답을 냅니다.
 3. **하네스 vs 바이브 토글** — RAG(출처 표시) 모드와 자유생성 모드를 나란히 비교하는 실험용 화면이 들어 있습니다.

2. 바뀌는 것 — URL 한 줄

결과부터: 이 앱은 이미 게이트웨이(:11500)로 설정되어 있습니다. 바꿀 것이 없습니다.

모델 주소가 `app.py` 맨 위 상수 두 줄에 들어 있고, 둘 다 `:11500` 을 가리킵니다.

```
# app.py 12~13번째 줄 (현재 상태 - 이미 게이트웨이)
OLLAMA_URL = "http://121.138.151.6:11500/api/chat"
EMBED_URL = "http://121.138.151.6:11500/api/embeddings"
```

원래(3주차)에는 이 두 줄이 각자 모델 서버인 `:11434` 를 가리키고 있었습니다. 4주차 전환은 바로 이 포트 번호 한 자리만 바꾸는 작업이었고, 이미 반영되어 있습니다.

```
# 만약 다시 :11434로 되어 있다면, 이렇게 한 줄씩만 고치면 됩니다
- OLLAMA_URL = "http://121.138.151.6:11434/api/chat" #
app.py:12
- EMBED_URL = "http://121.138.151.6:11434/api/embeddings" #
app.py:13
+ OLLAMA_URL = "http://121.138.151.6:11500/api/chat"
+ EMBED_URL = "http://121.138.151.6:11500/api/embeddings"
```

참고: 이 앱은 채팅뿐 아니라 **임베딩(검색)** 도 모델 서버를 씁니다(app.py:13). 그래서 `:11500` 으로 바꿀 때 **두 줄 다** 바뀌야 RAG 검색까지 정상 동작합니다 — 이미 둘 다 되어 있으니 그대로 두면 됩니다.

`MODEL = "qwen3.6:35b-a3b"` (app.py:14) 같은 모델명은 **건드리지 마세요**. 게이트웨이가 모델명 정규화·생각 끄기(think:false)·답변 길이 상한을 자동으로 처리하므로, 모델명이 조금 달라도 게이트웨이가 알아서 맞춰 줍니다.

3. 확인 절차

순서대로 따라 하면 됩니다. (터미널/명령 프롬프트에 그대로 붙여넣기)

① 게이트웨이가 살아 있는지 먼저 확인

```
curl http://121.138.151.6:11500/health
```

- 정상이면 **ok** 또는 상태 정보가 돌아옵니다. 응답이 없으면 강사에게 알려주세요(공유 서버 점검 필요).

② 내 앱 기동 (앱 폴더 안에서 실행)

```
python -m uvicorn app:app --port 8000
```

- 처음 질문할 때 터미널에  **DOCS 임베딩 중 (최초 1회)...** →  **8개 청크 캐시 완료** 가 뜨면 RAG 검색(임베딩)이 게이트웨이로 잘 붙은 것입니다.

③ 내 앱 자체 상태 확인

```
curl http://127.0.0.1:8000/health
```

- `{"status":"ok","index":8}` 처럼 나오면 정상(**index** 는 캐시된 안내 청크 수).

④ 대표 질문 1개로 끝까지 확인 (프론트 화면 또는 아래 명령)

```
curl -N -X POST http://127.0.0.1:8000/api/chat \
-H "Content-Type: application/json" \
-d '{"question":"A주차장에 2시간 세우면 주차비가 얼마예요?"}'
```

- 기대 답: **4,000원** (처음 30분 무료, 이후 30분당 1,000원 → 1.5시간분 = 4,000원). 코드 계산값이 그대로 인용되어야 합니다.

⑤ “생각 누출” 없는지 확인 (가장 중요)

- 답변 안에 `<think>` 나 모델이 혼잣말하는 추론 과정이 섞여 나오면 안 됩니다.
- 이 앱은 원래 `<think>` 제거 로직이 **없어서** raw 모델(**:11434**)에 붙이면 생각이 새어 나올 수 있었습니다. 이제 게이트웨이(**:11500**)가 `think:false` 를 자동으로 넣어 주므로 답변은 깔끔하게 본문만 나와야 정상입니다.
- 만약 생각이 보인다면 → app.py:12,13이 **:11500** 이 맞는지 다시 확인하세요(**:11434** 로 되어 있으면 누출됩니다).

4. 개선 1~2가지 (이 앱 약점 기반)

분석에서 짚은 약점 중, 실무에서 바로 효과 보는 2가지입니다.

① 서버 주소·모델명을 코드에 박지 말고 환경변수로 (하드코딩 제거) 지금은

121.138.151.6:11500 , 모델명이 app.py:12~15에 고정되어 있습니다. 서버 주소가 바뀌면 코드를 직접 고쳐야 합니다. 아래처럼 환경변수에서 읽게 하면, 코드를 안 건드리고 주소만

바꿀 수 있습니다.

```
import os
GATEWAY = os.getenv("GATEWAY_URL", "http://121.138.151.6:11500")
OLLAMA_URL = f"{GATEWAY}/api/chat"
EMBED_URL = f"{GATEWAY}/api/embeddings"
```

② 안전망으로 **<think> 한 줄 제거 (이중 방어)** 게이트웨이가 생각을 꺼 주지만, 만에 하나 raw 서버로 잘못 붙더라도 답변창이 더러워지지 않게 토큰을 흘려보내기 전에 한 번 걸러 주면 안심입니다. (app.py:183 토큰 추출 부근에 적용)

```
import re
token = re.sub(r"<think>.*?</think>", "", token, flags=re.S)
```

그 외(동시성): 공유 GPU가 1개라 여러 명이 동시에 질문하면 응답이 느려질 수 있습니다. 실습 중에는 질문을 한 번에 몰아 보내지 말고, 답이 다 나온 뒤 다음 질문을 보내 주세요.

5. 안전수칙 (콜센터 특화)

- **환자 개인정보·대외비 입력 금지.** 콜센터 특성상 환자번호·주민번호·진단명이 오갈 수 있는데, **절대 챗봇 입력창에 넣지 마세요.** 이 앱은 그런 패턴을 자동 차단하지만(app.py 개인 정보 차단), 차단은 보조장치일 뿐 1차 책임은 입력하는 사람에게 있습니다. 테스트는 **더미(가짜) 질문**으로만 하세요. 예: “외래 진료시간 알려주세요”, “면회 시간이 언제예요”.
- **안내 자료는 공개 안내문 수준만.** 이 앱의 8개 안내 청크는 일반 이용안내(주차·면회·증명서)라 민감도가 낮습니다. 새 안내문을 추가할 때도 **대외비·내부 운영 정보는 넣지 마세요.**
- **공유 서버 예절.** :11500 은 모두가 같이 쓰는 GPU 1개입니다. 대량 질문·반복 스트레스 테스트는 금지. 응답이 느리면 다른 사람이 쓰는 중일 수 있으니 잠시 기다리세요.
- **답변은 참고용.** 요금·시간 같은 숫자도 최종 안내 전에는 실제 규정으로 한 번 더 확인하세요(특히 주차요금 정책 변경 시).