

03. 의공팀 — 의료기기 수리 매뉴얼 챗봇 (DI-2200P)

1. 내 앱 한눈에

- **아키타입**: A형(RAG·근거검색) 중심 + B형(자동화) 혼합.
- **핵심기능**: 주입펌프 DI-2200P 수리 매뉴얼 8조각을 임베딩으로 검색(top-3)해 **근거(출처 칩 p.00)와 함께** 답하는 챗봇. 여기에 보유기기 ↔ 리콜공지 **로트 자동 대조**(파이썬이 숫자 확정 → 모델은 1~2줄 요약만)와 오류코드(E12/E15/E21/E33) 빠른 검색 칩이 붙어 있다.
- **구성**: `app.py` (FastAPI 백엔드, 포트 8000) + `index.html` (단일 정적 프론트, 포트 5500). 프론트는 백엔드만 부르고 모델을 직접 부르지 않는다(프론트/백엔드 분리 준수).

이 앱은 채팅(`/api/chat`)뿐 아니라 **임베딩(`/api/embeddings`)도 함께 호출**한다. 그래서 게이트웨이가 이 두 가지를 모두 받아준다는 점이 다른 앱보다 중요하다.

2. 바뀌는 것 — URL 한 줄

이미 게이트웨이(:11500)로 설정되어 있습니다. 추가로 바꿀 것이 없습니다. 아래는 현재 상태 확인용입니다.

`app.py:19-20` (현재 코드, 이미 패치 완료):

```
OLLAMA_URL = "http://121.138.151.6:11500/api/chat"      # 채팅
EMBED_URL   = "http://121.138.151.6:11500/api/embeddings" # 임베딩
```

- **원래 어디였나**: 두 줄 모두 처음엔 `:11434` (각자 띄우던 raw 포트)였습니다. 그 자리를 `:11500` (공유 게이트웨이)으로 바꾼 것이 4주차 작업의 전부입니다.
- 만약 어떤 사정으로 다시 `:11434` 로 되돌아가 있다면, 아래처럼 두 곳만 `:11500` 으로 고치면 됩니다(diff):

```
- OLLAMA_URL = "http://121.138.151.6:11434/api/chat"
- EMBED_URL  = "http://121.138.151.6:11434/api/embeddings"
+ OLLAMA_URL = "http://121.138.151.6:11500/api/chat"
+ EMBED_URL  = "http://121.138.151.6:11500/api/embeddings"
```

포인트: 이 앱은 **두 줄**을 바꿔야 합니다(채팅 + 임베딩). 다른 앱은 보통 한 줄입니다.

`app.py:21-22` 의 모델명(`qwen3.6:35b-a3b` , `bge-m3:latest`)은 게이트웨이가 정규화해 주므로 **건드리지 않아도 됩니다.**

3. 확인 절차

① 게이트웨이가 살아있나 (curl)

```
curl http://121.138.151.6:11500/health
```

정상이면 게이트웨이가 응답합니다. 이어서 모델 목록도 확인할 수 있습니다.

```
curl http://121.138.151.6:11500/api/tags
```

② 앱 기동 (백엔드 → 프론트, 터미널 2개)

백엔드(터미널 1):

```
cd 내-의료기기-앱-폴더 # app.py 가 들어 있는 본인 폴더로 이동
python -m uvicorn app:app --port 8000
```

프론트(터미널 2):

```
cd 내-의료기기-앱-폴더 # 같은 폴더(index.html 위치)
python -m http.server 5500
```

브라우저에서 `http://127.0.0.1:5500/index.html` 접속. 화면 상단 연결 상태 표시가 초록(정상)이면 앱이 백엔드와 붙은 것입니다.

③ 앱 자체 헬스 확인(선택) — 백엔드가 떴는지:

```
curl http://127.0.0.1:8000/health
```

```
{"status":"ok","docs_cached":...}
```

가 나오면 정상.

④ 대표질문 1개

채팅창에 입력:

E15 오류가 뜨는데 어떻게 하나요?

기대 답변: “E15: 압력센서 신호 불안정 → 캘리브레이션 필요(자격 기술자 전용)” 취지의 안내 + 끝에 출처 칩(근거: 센서 오류 코드 모음 (p.78)) + 안전 고지 한 줄.

⑤ think(추론) 누출 없는지 확인

- 답변 안에 `<think>` ... `</think>` 같은 모델의 혼잣말(추론 과정)이 보이면 안 됩니다. 게이트웨이(:11500)가 think를 자동으로 꺼주므로, 정상이라면 깔끔한 답변만 나옵니다.
- 이 앱의 모델은 `qwen3.6` (추론형)이라 raw `:11434` 로 직접 부르면 추론 텍스트가 새기 쉽습니다. `:11500` 으로 바꾼 뒤 그 증상이 사라졌는지 눈으로 확인하세요. 만약 여전히 `<think>` 가 보이면 URL이 `:11434` 로 남아 있는지 `app.py:19` 를 다시 보세요.

4. 개선 1~2가지

(개선 1) 하드코딩된 주소를 환경변수로 빼기 — 분석 §“걸림돌 1·4”

지금은 호스트·포트·모델명이 코드에 박혀 있어, 서버가 바뀌면 매번 코드를 고쳐야 합니다. 다음처럼 바꾸면 코드 수정 없이 운영 환경만 바꿔 끼울 수 있습니다.

```
import os
BASE = os.getenv("LLM_BASE", "http://121.138.151.6:11500")
OLLAMA_URL = f"{BASE}/api/chat"
EMBED_URL = f"{BASE}/api/embeddings"
```

```
MODEL = os.getenv("LLM_MODEL", "qwen3.6:35b-a3b")
MBED_MODEL = os.getenv("EMBED_MODEL", "bge-m3:latest")
```

이러면 주소가 한 곳(`BASE`)에 모여, 다음에 게이트웨이 주소가 바뀌어도 한 줄만 고치면 됩니다.

(개선 2) 임베딩 호출 실패에 대한 안내 처리 — 분석 §“걸림돌 2·3”

이 앱의 핵심(RAG)은 임베딩(`/api/embeddings`)이 반드시 살아 있어야 합니다. 만약 게이트웨이가 임베딩을 못 주면 `res.json()["embedding"]` (`app.py:105`)에서 에러가 나면서 화면이 멈춘 것처럼 보입니다. 사용자에게 “지금은 검색 기능을 쓸 수 없습니다(바이트 모드로 시도하세요)”라고 안내하도록 `embed()` 에 예외 처리를 넣으면, 장애 시에도 앱이 죽지 않고 부드럽게 동작합니다. (코드를 많이 못 만지면, 최소한 화면 안내 문구라도 추가)

5. 안전수칙 (이 과제 특화)

- **환자정보·실데이터 입력 금지:** 질문·리콜대조 입력에는 환자 이름·환자번호·실제 시리얼/로트 등을 넣지 마세요. 실습은 **더미·비식별 값만**(예: 로트 `L2401` , `L2402`).
- **매뉴얼 내용은 안내용, 시술/수리 지시 아님:** 이 챗봇은 자료에 있는 내용만 안내합니다. 답변 끝의 “⚠️ 자격 기술자 전용 — 임의 분해·내부 수리 금지, 환자 연결 상태 점검 금지” 고지를 반드시 함께 읽으세요. 실제 분해·수리는 자격 기술자/제조사 서비스 대상입니다.
- **리콜 대조 결과는 더블체크:** 숫자(건수·로트)는 파이썬이 계산해 정확하지만, 입력 JSON 자체가 더미라면 결과도 더미입니다. 실제 리콜 판단은 공식 공지로 확인하세요.
- **공유 GPU 1개 — 동시성 주의:** 게이트웨이 뒤의 GPU는 1개를 모두가 같이 씁니다. 긴 질문을 연달아 던지지 말고, 답이 끝난 뒤 다음 질문을 보내세요. 여러 명이 동시에 몰리면 응답이 느려질 수 있습니다.