

04. 인사 — 휴가안내

4주차 한 줄 컨셉: “공유 게이트웨이(:11500) 위에서 내 앱을 운영급으로.” 각자 모델을 따로 띄울 필요 없이, 게이트웨이가 추론 누출(생각 과정 노출) 차단·답변 길이 상한·모델명 자동 보정을 한곳에서 처리합니다. 내 앱은 **모델 주소 한 줄만 :11500** 으로 가리키면 끝.

🔴 이 가이드는 **일반형**입니다. 4주차에 제출된 코드가 없어서, 본인 코드의 정확한 줄번호 대신 **A RAG 과제의 표준 모양**을 기준으로 “게이트웨이에 붙이는 법”을 안내합니다. 3주차에 만든 휴가 챗봇이 있다면 그 위에서, 아직 없다면 4번 절(아직 코드가 없다면)부터 출발선을 맞추세요.

1. 내 앱은 이런 모양 (A RAG 표준 구조)

휴가안내 챗봇은 **A형 — RAG(검색 기반 안내)**입니다. 사내 휴가 규정을 조각으로 나눠 두고, 질문과 가까운 조각만 골라(검색) 그 근거로만 답하는 구조입니다. “규정에 있는 것만 답하고, 없으면 확인 불가”가 핵심 안전장치입니다.

데이터가 흐르는 길은 딱 세 칸입니다.

[프론트: index.html]

질문 한 줄을 보냄 (이 화면은 오직 내 백엔드만 부른다)



[내 백엔드: app.py → http://127.0.0.1:8000]

① 규정 8조각을 검색(임베딩)해서 가까운 조각을 고르고

② 고른 조각을 근거로 채팅 모델에게 답을 받아 다시 프론트로 흘려줌



[공유 게이트웨이: http://121.138.151.6:11500]

↳ 그 뒤에 공유 GPU(모델 서버 1대)가 있음

- **프론트(index.html)**는 모델을 **직접 부르지 않습니다**. 항상 내 백엔드(:8000)에게만 말을 겁니다. (프론트가 모델을 직접 부르면 CORS·보안 사고가 납니다 — 3주차 분리 원칙.)
- **내 백엔드(app.py, :8000)**가 두 종류의 모델 호출을 대신합니다.
 1. **검색(임베딩)** — 규정 조각과 질문을 벡터로 바꿔 가까운 조각을 고름. (3주차 기준 모델 `bge-m3:latest`)
 2. **답변(채팅)** — 고른 조각을 근거로 자연스러운 답을 생성. (3주차 기준 모델 `qwen3.6:35b-a3b`)
- 3주차까지는 이 두 호출의 주소 끝이 `:11434` (각자 PC에서 직접 띄우는 raw 포트)였습니다. **4주차에 바꾸는 건 이 주소의 포트 숫자 하나뿐입니다 → :11500**.

한 줄 요약: **프론트(:8000만 부름) → 내 백엔드(:8000) → 게이트웨이(:11500)**. 4주차에 손대는 건 맨 오른쪽 칸 주소 한 군데입니다.

2. 바뀌는 것 — URL 한 줄

내 백엔드(`app.py`) 맨 위에 모델 서버 주소를 담는 변수가 있습니다. 그 주소의 포트만 **11500** 으로 두면 됩니다. IP(`121.138.151.6`)는 그대로입니다.

```
# app.py 맨 위 - 4주차 표준 (이 한 줄이 핵심)
OLLAMA_URL = "http://121.138.151.6:11500"
```

이 앱은 검색(임베딩)과 답변(채팅) **두 가지 호출**을 쓰므로, 둘 다 같은 게이트웨이를 가리키게 합니다. 보통 한 변수에서 만들어 씁니다.

```
OLLAMA_URL = "http://121.138.151.6:11500"
CHAT_URL    = f"{OLLAMA_URL}/api/chat"      # 답변(채팅) 호출
MBED_URL    = f"{OLLAMA_URL}/api/embeddings" # 검색(임베딩) 호출
```

3주차 코드처럼 주소가 두 줄로 따로 적혀 있다면, **두 줄 다** 포트만 바꿔 주세요. (한 줄만 바꾸면 검색 또는 답변 중 한쪽이 raw로 남습니다.)

```
- CHAT_URL = "http://121.138.151.6:11434/api/chat"
- EMBED_URL = "http://121.138.151.6:11434/api/embeddings"
+ CHAT_URL = "http://121.138.151.6:11500/api/chat"
+ EMBED_URL = "http://121.138.151.6:11500/api/embeddings"
```

모델명·옵션은 그대로 뒤도 됩니다. `qwen3.6:35b-a3b` (채팅), `bge-m3:latest` (임베딩) 같은 모델명을 손댈 필요 없습니다. 게이트웨이가 **모델명을 알아서 보정**해 공유 서버의 실제 모델로 연결하고, **생각 끄기(think:false)**와 **답변 길이 상한(num_predict)**도 한곳에서 처리합니다. 즉 학생은 주소 한 줄만 신경 쓰면 됩니다.

💡 한 발 더: 주소를 코드에 박는 대신 환경변수로 빼두면, 코드를 안 고치고도 서버가 바뀔 때 대응할 수 있습니다.

```
import os
OLLAMA_URL = os.environ.get("OLLAMA_URL",
                             "http://121.138.151.6:11500")
```

3. 확인 절차

순서대로 따라 하세요. (터미널/명령 프롬프트에 그대로 붙여넣기)

① 게이트웨이가 살아 있는지 먼저 확인 — `/health`

```
curl http://121.138.151.6:11500/health
```

- 정상이면 `ok` (또는 짧은 상태 JSON)가 돌아옵니다.
- 응답이 없으면 게이트웨이가 꺼져 있거나 네트워크 문제입니다. 강사에게 알려세요. (이게 안 되면 챗봇도 당연히 안 됩니다.)
- 원하면 모델 목록도 확인할 수 있습니다: `curl http://121.138.151.6:11500/api/tags`

② 내 앱 기동 (앱 폴더 안에서 실행)

```
python -m uvicorn app:app --port 8000
```

- 처음 질문할 때 터미널에 임베딩 캐시 로그(예: `DOCS 임베딩 중 (최초 1회)... → 8 개 체크 캐시 완료`)가 뜨면 검색(임베딩)이 게이트웨이로 잘 붙은 것입니다.

③ 내 앱 자체 상태 확인 (있는 경우)

```
curl http://127.0.0.1:8000/health
```

- `{"ok":true}` 처럼 나오면 백엔드가 정상 기동된 것입니다.

④ 대표 질문 1개로 끝까지 확인 (프론트 화면 또는 아래 명령)

브라우저에서 챗봇 입력창에 한 줄 넣어 봅니다.

“병가 진단서 필요해?”

기대 동작: [병가] 조각을 근거로 “연속 3일 이상 사용 시 의사 진단서 제출” 같은 답이 나오고, 답 아래에 작은 회색 글씨로 출처: [병가] 가 붙습니다.

화면 대신 명령으로 확인하려면 (엔드포인트 이름은 본인 코드에 맞게)

```
curl -N -X POST http://127.0.0.1:8000/api/chat \
-H "Content-Type: application/json" \
-d '{"question":"병가 진단서 필요해?"}'
```

⑤ “생각 누출(think)” 없는지 확인 — 가장 중요

- 답변 안에 `<think> ... </think>` 같은 모델의 사고 과정 텍스트가 그대로 보이면 안 됩니다. 게이트웨이(:11500)를 쓰면 이 부분이 자동으로 걸려져 깔끔한 최종 답만 나옵니다.
- 혹시 `<think>` 가 보이거나 답이 비어서 나온다면, 심중팔구 주소가 다시 `:11434` (raw)로 남아 있는 것입니다. 2번 절의 `CHAT_URL · EMBED_URL` 이 둘 다 `:11500` 인지 다시 확인하세요.
- 추가 확인: “안식년 며칠이야?”(규정에 없는 질문)에 지어내지 않고 “확인 불가 — 인사팀에 문의하세요”로 답하면, RAG 안전장치까지 정상입니다.

4. 아직 코드가 없다면 (3주차 STEP0 캐치업으로 출발선 맞추기)

4주차에 제출한 코드가 없다면, 먼저 3주차 휴가안내 핸드아웃의 공통 STEP 0으로 출발선을 맞춥니다. STEP 0은 모든 과제가 공유하는 기본 골격(백엔드 `app.py` + 프론트 `index.html`)이고, 그 위에 휴가 챗봇 기능을 엮는 방식입니다.

STEP 0으로 출발선 맞추는 순서

1. 3주차 휴가안내 핸드아웃을 연다 — `lecture/3주차_강의_개인별/3주차_강의_04_휴가안내.pdf`. (공통부 = 백엔드 → 프론트 → 실행 ①②③.)
2. 공통 STEP 0 기본코드를 띄운다 — `app.py` (FastAPI, :8000)와 `index.html` 이 뜨고 화면에 ● 연결됨 이 보이면 출발선 도착.

3. **휴가 규정 더미 8조각을 넣는다** — 3주차 핸드아웃의 더미(아래)를 그대로 사용합니다. **실제 사내 규정은 넣지 마세요.**

[연차] 1년 이상 만근 15일, 이후 3년마다 1일 가산(상한 25일). 첫째는 1개월 만근마다 1일(최대 11일).

[병가] 연 60일 이내. 연속 3일 이상 사용 시 의사 진단서 필수. 장기 병가는 인사팀 사전 협의.

[반차·반반차] 반차 0.5일 차감(오전/오후), 반반차 2시간 단위 0.25일 차감.

[경조] 본인 결혼 5일, 자녀 결혼 1일, 배우자 출산 10일, 부모·배우자·자녀 사망 5일, 조부모·형제자매 사망 3일.

[공가] 예비군·민방위 소집 기간, 법정 건강검진·헌혈 1일, 법원 출석 등.

[특별휴가] 여름휴가 연 3일(7~9월, 미사용 소멸), 장기근속 10년 5일·20년 10일, 난임치료 연 3일.

[신청절차] 휴가 3일 전까지 전자결재 상신, 응급 시 사후 24시간 내. 결재선 팀장 → 부서장.

[이월] 미사용 연차 다음 해 최대 5일 이월, 이월분 우선 사용. 특별휴가는 이월 불가.

4. **단 하나만 4주차식으로** — STEP 0이 뜨자마자, 백엔드의 모델 주소를 **:11434** → **:11500** (2번 절)으로 바꿉니다. 이것만 하면 4주차 출발선 완료입니다.

5. **그다음 휴가 챗봇 기능을 엮는다** — 3주차 핸드아웃의 프롬프트 ①(휴가 안내로 맞추기) → ②(출처 표시) → ③(확인 불가) 순으로 복붙하면 됩니다. 검색(임베딩)·집계 계산까지 가고 싶으면 그 뒤 프롬프트를 이어서.

핵심: **출발선만 3주차에서 빌려오고, 그 위에서 주소 한 줄만 4주차(:11500)로 바꾸면 됩니다.**
코드를 처음부터 다시 만들 필요는 없습니다. 막히면 3번 절의 **/health** 부터 차근차근 확인하세요.

5. 안전수칙 (휴가안내 특화)

- **개인 휴가내역·잔여일수 금지** — 이 앱은 **규정 안내 전용**. “내 연차 며칠 남았어?” 같은 개인 사용내역은 묻지도, 입력받지도, 저장하지도 않습니다. 챗봇은 “개인 휴가내역은 이 챗봇에서 확인할 수 없습니다”로 답해야 정상입니다.
- **실제 사내 규정·실명·사번 입력 금지** — **더미·비식별만**. 테스트는 위 더미 8조각으로만 합니다. 실제 인사 규정 문서나 직원 개인정보(이름·사번·진단명 등)는 절대 챗봇이나 코드에 넣지 마세요. 비식별·가짜 데이터로만 연습합니다.
- **규정에 없으면 반드시 “확인 불가”**. 지어낸 일수·금액·조건은 인사 사고로 이어집니다. RAG가 근거 조각을 못 찾으면 “확인 불가 — 인사팀에 문의하세요”로 막혀야 합니다.
- **공유 GPU는 하나뿐** — **동시성 주의**. **:11500** 뒤의 모델 서버는 **여러 명이 함께 쓰는 GPU 1대**입니다. 한꺼번에 긴 질문을 몰아넣으면 모두 느려집니다. 답이 다 나온 뒤 다음 질문을 보내고, 응답이 느리면 잠시 기다리세요(다른 사람이 쓰는 중일 수 있습니다).
- **답변은 참고용**. 휴가 일수·신청 기한 같은 숫자도 실제 신청·승인 전에는 인사팀·결재선으로 한 번 더 확인하세요.