

05. 약제부 — hira비급여조회

4주차 한 줄 컨셉: “공유 게이트웨이(:11500) 위에서 내 앱을 운영급으로.” 각자 모델을 띄울 필요 없이, 게이트웨이가 추론 누출(think) 차단·답변 길이 상한·모델명 자동 보정을 한곳에서 처리한다. 내 앱은 **모델 주소 한 줄만** 가리키면 끝.

1. 내 앱 한눈에

- **아키타입**: 주로 **C(조회·검색)** 형. 건강보험심사평가원(심평원, HIRA) 공공데이터로 전국 병원의 **비급여 진료비를 검색·필터·비교**하는 앱이다. 여기에 **안내 챗봇(B/어시스턴트형)**이 곁들여져 있다.
- **핵심 기능**: ① 항목명·지역·병원종별 필터 검색 + 페이지네이션, ② 심평원 전체 데이터를 백그라운드로 미리 받아두는 캐시(`cache.pkl`), ③ API 키가 없으면 샘플 데이터(약 90건)로 풀백, ④ 안내 챗봇이 답변 안에 `[SEARCH:키워드]`를 넣으면 클릭형 검색 버튼으로 바뀐다.
- **구조**: 파이썬 Flask 단일 파일(`app.py`) + 화면 한 장(`templates/index.html`). 챗봇은 브라우저가 모델을 직접 부르지 않고, **백엔드(Flask)가 모델 서버로 대신 호출(프록시)**한다. (근거: 분석문서 `1_hira-app.md` 기능·AI 모델 호출 분석 절)

2. 바뀌는 것 — URL 한 줄

이 앱에서 AI 모델을 부르는 주소는 `app.py` **17번째 줄** 한 곳에 모여 있다. 챗봇 호출(`app.py:503`)과 모델목록 조회(`app.py:518`)가 모두 이 변수(`OLLAMA_URL`)를 가져다 쓴다.

✅ **결론부터: 이미 게이트웨이로 설정됨**

이 앱은 이미 **:11500 (공유 게이트웨이)**로 패치가 끝난 상태다. 지금 코드는 이렇게 돼 있다.

`app.py` 17번째 줄 — 현재 상태(그대로 두면 됨)

```
OLLAMA_URL = os.environ.get("OLLAMA_URL",  
"http://121.138.151.6:11500")
```

- 원래(제출 당시, 백업 파일 `app.py.bak`)에는 끝이 **:11434** 였다. 11434는 “각자 자기 PC에서 모델을 직접 띄울 때” 쓰는 raw 포트라서, 생각 과정이 그대로 새어 나오거나 답이 비는 문제가 생길 수 있다.
- 지금은 그 한 글자(정확히는 포트 숫자)만 **:11500**으로 바뀌어 있다. **이 줄은 더 손대지 않아도 된다.**

참고: 만약 다시 **:11434**로 되돌아가 있다면 (혹은 직접 확인하고 싶다면)

아래처럼 **포트 숫자만 11500**으로 고치면 된다. IP(`121.138.151.6`)는 그대로 둔다.

```
- OLLAMA_URL = os.environ.get("OLLAMA_URL",  
"http://121.138.151.6:11434")  
+ OLLAMA_URL = os.environ.get("OLLAMA_URL",  
"http://121.138.151.6:11500")
```

모델명은 신경 쓰지 않아도 된다. `app.py:18` 의 `CHAT_MODEL = "qwen2.5:14b-instruct-q4_K_M"` 는 그대로 뒤도 게이트웨이가 **모델명을 알아서 보정**해서 공유 서버의 실제 모델로 연결해 준다. 마찬가지로 추론 누출 차단(`think:false`)과 답변 길이 상한도 게이트웨이가 처리하므로, `app.py:498` 의 `num_predict` 같은 옵션도 그대로 뒤도 안전하다.

3. 확인 절차

(1) 게이트웨이가 살아있나 — `/health`

먼저 공유 게이트웨이가 켜져 있는지 확인한다. 터미널에 그대로 붙여넣자.

```
curl http://121.138.151.6:11500/health
```

- 정상이면 `ok` (또는 상태를 알리는 짧은 JSON)가 돌아온다.
- 응답이 없으면 게이트웨이가 꺼져 있거나 네트워크 문제다. 강사에게 알린다. (이 단계가 안 되면 챗봇도 당연히 안 된다.)

(원하면 모델 목록도 확인할 수 있다.)

```
curl http://121.138.151.6:11500/api/tags
```

(2) 내 앱 기동 — 정확한 실행 명령

앱 폴더에서 아래를 실행한다. (`run.sh` 가 `.env` 의 API 키를 읽고 `python3 app.py` 를 띄워준다.)

```
cd hira-app/hira-app  
./run.sh
```

- ⚠️ **접속 포트 주의:** `run.sh` 는 화면에 “http://localhost:5000”이라고 안내하지만, 실제 코드(`app.py:527`)의 기본 포트는 **8080**이다. 환경변수 `PORT` 를 따로 지정하지 않았다면 **브라우저에서 `http://localhost:8080` 으로 접속**해야 한다. (안내문과 실제 포트가 다른 점은 4번 '개선'에서 다룬다.)
- 5000으로 고정하고 싶다면 이렇게 띄운다.

```
PORT=5000 ./run.sh
```

이때는 `http://localhost:5000` 으로 접속

(3) 대표 질문 1개로 챗봇 테스트

브라우저에서 앱을 열고 챗봇 입력창에 아래를 넣어본다.

“창원에서 무릎 인공관절 수술 비급여 가격이 궁금해요”

기대 동작: 챗봇이 비급여 안내를 간결하게(3~5문장) 답하고, 답변 안에 [SEARCH: 인공관절] 같은 검색 버튼이 생겨 클릭하면 검색 결과로 연결된다.

(4) think(생각 과정) 누출 없는지 확인

- 답변에 `<think>` ... `</think>` 같은 사고 과정 텍스트가 그대로 보이면 안 된다. 게이트웨이(:11500)를 쓰면 이 부분이 자동으로 걸러져서 **깔끔한 최종 답만** 나온다.
- 혹시 `<think>` 가 보이거나 답이 비어서 나온다면, 심종팔구 주소가 다시 `:11434` (raw)로 돌아가 있는 것이다. 2번 절의 `app.py:17` 을 다시 확인한다.

4. 개선 1~2가지 (이 앱의 약점 기반)

분석문서가 짙은 약점을 토대로 한 구체 제안이다.

개선 ① 접속 포트 혼선 정리 (안내문 5000 ↔ 실제 8080). 지금은 `run.sh` (5000 안내)와 `app.py:527` (기본 8080)이 어긋나 있어, 처음 쓰는 사람이 “주소를 쳤는데 안 떠요” 하기 쉽다. 둘 중 하나로 통일하자. 가장 간단한 방법은 `run.sh` 의 안내 문구를 실제 기본값과 맞추는 것이다.

```
# run.sh 22번째 줄
- echo "✅ http://localhost:5000 으로 접속하세요"
+ echo "✅ http://localhost:8080 으로 접속하세요"
```

(또는 반대로 `app.py:527` 의 기본값을 `8080` 대신 `5000` 으로 바꿔도 된다. 핵심은 **안내와 실재를 일치**시키는 것.)

개선 ② API 키 평문 노출 정리. `.env` 파일에 심평원 API 키(`HIRA_API_KEY`)가 평문으로 들어 있고, 제출물에도 그대로 포함됐다. 키는 비밀번호와 같다. 공유·재배포할 때는 ① 실제 키를 지우고 `.env.example` (빈 값 예시)만 남기고, ② 본인만 쓰는 진짜 `.env` 는 따로 보관한다. 추가로 모델 주소·모델명도 `.env` 에 넣어두면 코드를 안 고치고도 환경마다 바꿀 수 있어 더 깔끔하다.

```
# .env (예시 - 실제 키는 본인 것으로, 외부 공유 금지)
HIRA_API_KEY=발급받은키
OLLAMA_URL=http://121.138.151.6:11500
CHAT_MODEL=qwen2.5:14b-instruct-q4_K_M
```

참고로 분석문서가 지적한 또 다른 약점(챗봇이 모델의 생각 과정을 따로 걸러내지 않는 점)은 **게이트웨이로 바꾼 것만으로 이미 해결**된다. 앱 코드를 고칠 필요 없이 :11500이 알아서 처리해 주기 때문이다.

5. 안전수칙 (이 과제 특화)

- **비급여 가격은 공공데이터다 — 그래도 환자정보는 금지.** 이 앱이 다루는 비급여 진료비는 누구나 볼 수 있는 심평원 공개 데이터다. 하지만 챗봇 입력창에는 **환자 이름·등록번호·진단명 같은 개인정보(PHI)나 대외비를 절대 넣지 말 것**. 질문은 “OO 수술 비급여 가격대”처럼 **항목 단위**로만.
- **샘플·캐시 데이터 그대로 외부 반출 금지.** 코드 안 `MOCK_DATA` 에는 실제 병원명과 가공 가격이, `cache.pkl` 에는 공공데이터가 대량으로 들어간다. 교육용으로만 쓰고, 이 파일들을 외부로 보내지 않는다.

- **API 키는 비밀번호처럼.** `.env` 의 심평원 키를 메신저·메일·외부 저장소에 그대로 올리지는 않는다(개선 ② 참고).
- **공유 GPU는 하나뿐 — 동시성 주의.** :11500 뒤의 모델 서버는 **여러 명이 함께 쓰는 GPU 1대**다. 한꺼번에 긴 질문을 몰아넣으면 모두 느려진다. 특히 이 앱은 결 때 심평원 전체 데이터를 **8개 스레드로 동시에 받아오는**(`app.py:282`) 부담이 있으니, 여러 명이 동시에 첫 기동을 하지 말고 순서대로 띄운다. 답변이 느리면 잠시 기다린다(서버를 탭하지 말 것).