

06. 인사 — 복리후생

4주차 한 줄 컨셉: “공유 게이트웨이(:11500) 위에서 내 앱을 운영급으로.” 각자 모델을 띄울 필요 없이, 게이트웨이가 추론 누출(think) 차단·답변 길이 상한·모델명 자동 보정을 한곳에서 처리한다. 내 앱은 **모델 주소 한 줄만** 가리키면 끝.

이 가이드는 ‘일반형’입니다. 이번에 제출한 코드가 따로 없어서, 본인 코드의 정확한 줄번호 대신 **경조 복리후생 챗봇(A RAG)의 표준 모양**을 기준으로 “게이트웨이에 붙이는 법”을 안내합니다. 3주차에 만든 본인 챗봇이 있으면 그 위에, 없으면 4번 ‘아직 코드가 없다면’부터 시작하세요. (3주차 개인 핸드아웃: [3주차_강의_개인별/3주차_강의_06_복리후생.pdf](#))

1. 내 앱은 이런 모양 (경조 복리후생 챗봇 표준 구조)

이 과제는 **A형(RAG 챗봇)**입니다. 직원이 “부모 사망 휴가 며칠?”, “결혼하면 경조금 얼마?” 같은 질문을 하면, **경조 규정 표에서 관련된 줄만 골라(검색)** 그 값으로 답하는 챗봇입니다. 표를 통째로 모델에 넘기는 게 아니라, **질문과 가까운 줄만** 근거로 주는 것이 핵심(RAG)입니다.

구조는 세 칸으로 나뉩니다. 이 3단 구조가 모든 A RAG 과제의 표준이고, 4주차에 바뀌는 건 맨 오른쪽 화살표 하나뿐입니다.



- **프론트(index.html)**: 직원이 질문을 치는 화면. 모델을 **직접 부르지 않습니다**. 항상 내 백엔드(:8000)에만 말을 겁니다.
- **내 백엔드(app.py, :8000)**: 질문을 받아 ① 경조표 조각 중 가까운 줄을 찾고(임베딩 검색), ② 그 줄을 근거로 채팅 모델을 부릅니다. **모델 호출은 전부 여기(백엔드)서** 일어납니다.
- **공유 게이트웨이(:11500)**: 여러 사람이 같이 쓰는 모델 서버 입구. 추론 과정 누출 차단·답변 길이 제한·모델명 보정을 **자동으로** 해 줍니다. 내가 코드로 신경 쓸 필요가 없습니다.

핵심 한 줄: “**프론트는 백엔드만, 백엔드는 게이트웨이만.**” 화면(HTML)에서 모델을 직접 부르면 보안·CORS 사고가 납니다.

2. 바뀌는 것 — URL 한 줄

3주차에는 백엔드가 모델을 **:11434** (각자 PC에서 직접 띄우는 raw 포트) 로 불렀습니다. 4주차에는 이 **포트 숫자만 :11500** (공유 게이트웨이) 으로 바꿉니다. IP(**121.138.151.6**)는 그대로 둡니다.

app.py 위쪽에 모델 주소를 모아둔 변수를 하나 만들고(없으면 추가), 그 값을 **:11500** 으로 둡니다. 이 표준 모양이면 됩니다.

app.py 위쪽 — 모델 주소를 한 곳에 모아둔다 (이 줄 하나만 신경 쓰면 됨)

```
OLLAMA_URL = "http://121.138.151.6:11500"
```

```
CHAT_MODEL = "qwen3.6:35b-a3b" # 답변(채팅) 모델 — 그대로 뒤도 게이트웨이가 보정
```

```
EMBED_MODEL = "bge-m3:latest" # 검색(임베딩) 모델
```

이미 3주차 코드가 있다면, 모델을 부르는 줄에서 **11434**만 찾아 **11500**으로 바꾸면 끝입니다.

```
- OLLAMA_URL = "http://121.138.151.6:11434"
```

```
+ OLLAMA_URL = "http://121.138.151.6:11500"
```

채팅 호출과 임베딩 호출 모두 이 **OLLAMA_URL**을 가져다 쓰게 하면, 한 줄만 고쳐도 전부 게이트웨이를 타게 됩니다.

답변(채팅) 호출

```
requests.post(f"{OLLAMA_URL}/api/chat", json={...})
```

검색(임베딩) 호출

```
requests.post(f"{OLLAMA_URL}/api/embeddings", json={...})
```

모델명·옵션은 신경 쓰지 않아도 됩니다. **CHAT_MODEL**을 그대로 뒤도 게이트웨이가 공유 서버의 실제 모델로 알아서 연결합니다. 추론 과정 차단(think:false)과 답변 길이 상한도 게이트웨이가 처리하므로, 코드에 **num_predict**나 **think** 옵션을 따로 박지 않아도 안전합니다. **그게 바로 “하네스를 인프라로 끌어올린다”는 뜻** — 앱마다 박던 규칙을 게이트웨이 한 곳에서 처리합니다.

3. 확인 절차

(1) 게이트웨이가 살아있나 — **/health**

먼저 공유 게이트웨이가 켜져 있는지 확인합니다. 터미널에 그대로 붙여넣으세요.

```
curl http://121.138.151.6:11500/health
```

- 정상이면 **ok** (또는 상태를 알리는 짧은 JSON)가 돌아옵니다.
- 응답이 없으면 게이트웨이가 꺼져 있거나 네트워크 문제입니다. 강사에게 알려세요. (이 단계가 안 되면 챗봇도 당연히 안 됩니다.)

(원하면 모델 목록도 확인할 수 있습니다.)

```
curl http://121.138.151.6:11500/api/tags
```

(2) 내 앱 기동

앱 폴더에서 백엔드를 띄웁니다. (폴더 구조에 따라 명령은 조금 다를 수 있습니다.)

```
python3 app.py
# 또는 uvicorn 사용 시
uvicorn app:app --port 8000
```

기동되면 터미널에 `127.0.0.1:8000` (또는 `0.0.0.0:8000`)에서 대기한다는 메시지가 뜹니다. 브라우저로 `index.html` 을 엽니다.

(3) 대표 질문 1개로 테스트

챗봇 입력창에 아래를 넣어보세요.

“부모 사망 휴가 며칠인가요?”

기대 동작: 경조표에서 ‘부모 사망’ 줄을 골라 “**휴가 5일**” 처럼 표 값 그대로 답하고, 가능하면 어느 줄을 근거로 썼는지 **출처**를 함께 보여줍니다. (집계 질문 예: “사망 경조 중 경조금 제일 많은 항목?” → “배우자 사망”)

(4) think(생각 과정) 누출 없는지 확인

- 답변에 `<think>` ... `</think>` 같은 사고 과정 텍스트가 그대로 보이면 안 됩니다. 게이트웨이(:11500)를 쓰면 이 부분이 자동으로 걸러져 **깔끔한 최종 답만** 나옵니다.
- 혹시 `<think>` 가 보이거나 답이 비어서 나온다면, 십중팔구 주소가 다시 `:11434` (raw)로 돌아가 있는 것입니다. 2번 절의 `OLLAMA_URL` 을 다시 확인하세요. (이게 3주차에서 가장 많이 나온 증상이고, :11500이 정확히 그걸 잡아줍니다.)

4. 아직 코드가 없다면 — 3주차 STEP0 캐치업으로 출발선 맞추기

이번에 제출한 코드가 없어도 괜찮습니다. 3주차 공통 **STEP 0 기본코드**

(`app.py` · `index.html`)가 모두 같은 출발선입니다. 아래 순서로 따라오세요.

- STEP 0 기본코드 받기/열기.** 3주차 개인 핸드아웃(`3주차_강의_개인별/3주차_강의_06_복리후생.pdf`)의 STEP 0 부분을 보면, 프론트(`index.html`)와 백엔드(`app.py`)가 이미 연결된 기본 챗봇이 있습니다. 이게 1번 그림의 3단 구조 그대로입니다.
- 경조표 조각(DOCS)을 넣기.** 백엔드 `app.py` 안에 경조 규정을 **한 줄=한 조각**으로 넣습니다. 이게 검색의 재료입니다. (아래는 교육용 **더미** 표 — 실제 사규가 아닙니다.)

DOCS = [

 "본인 결혼: 휴가 5일 / 경조금 (7년이상)300,000원 (7년미만)200,000원",

 "자녀 결혼: 휴가 1일 / 경조금 (7년이상)200,000원 (7년미만)100,000원",

 "배우자 출산: 휴가 10일 / 경조금 확인필요",

 "부모 사망: 휴가 5일 / 경조금 (7년이상)500,000원 (7년미만)300,000원",

 "배우자 사망: 휴가 5일 / 경조금 (7년이상)1,000,000원 (7년미만)700,000

원",

"형제자매 사망: 휴가 3일 / 경조금 (7년이상)200,000원 (7년미만)100,000원",

]

3. 모델 주소를 :11500 으로. 2번 절의 OLLAMA_URL = "http://121.138.151.6:11500" 한 줄을 둡니다. (3주차 핸드아웃은 :11434 로 적혀 있으니, 그 숫자만 11500 으로 바꾸면 됩니다.)
4. 검색(RAG) 없기. 질문이 오면 → 질문을 임베딩(bge-m3:latest)해서 → DOCS 중 가까운 줄 TOP_K=2 개를 골라 → 그 줄을 근거로 채팅 모델(qwen3.6:35b-a3b)을 부릅니다. 이 전체 흐름과 복붙용 프롬프트는 3주차 핸드아웃의 프롬프트 1~6에 그대로 있습니다.
5. 3번 절 '확인 절차'로 점검. /health → 앱 기동 → "부모 사망 휴가 며칠?" → think 누출 없는지.

요점: 출발선만 맞추면 4주차 작업은 "URL 한 줄"이 전부입니다. 검색·규칙·출처 표시는 3주차에서 이미 만든 그대로 동작하고, 게이트웨이가 운영급 품질(누출 차단·길이 상한)을 위에서 입혀줍니다.

5. 안전수칙 (이 과제 특화 — 더미·비식별만)

- 개인 경조내역은 절대 입력 금지. 직원 이름·사번·신청 사유·실제 신청 내역 같은 개인정보를 챗봇에 넣지 마세요. 질문은 "부모 사망 휴가 며칠?", "결혼 경조금 얼마?" 처럼 항목 단위로만 합니다. (이름이 필요하면 "직원 A" 같은 더미로.)
- 경조표는 더미·비식별만. DOCS 에 넣는 표는 교육용 더미 값입니다. 실제 사규 경조표(대외비일 수 있음)를 그대로 넣어 외부 모델·외부 저장소로 보내지 마세요. 실데이터 확장은 추후 내부망에서만 진행합니다.
- 추정·계산 금지, 비면 "확인필요". 금액·휴가일수는 검색된 표 조각의 값만 그대로 옮깁니다. 표에 없으면 숫자를 지어내지 말고 "확인필요 — 인사팀 문의"로 답하게 합니다. (경조금은 직원에게 민감한 숫자라 환각이 특히 위험합니다.)
- 프론트에서 모델 직접 호출 금지. HTML/자바스크립트에서 11434 · 11500 · ollama 를 직접 부르지 마세요. 모델 호출은 오직 백엔드(:8000)를 거칩니다. (보안·CORS 사고 방지)
- 공유 GPU는 하나뿐 — 동시성 주의. :11500 뒤의 모델 서버는 여러 명이 함께 쓰는 GPU 1대입니다. 한꺼번에 긴 질문을 몰아넣으면 모두 느려집니다. 답변이 느리면 잠시 기다리세요(서버를 탓하지 말 것). 게이트웨이 주소(121.138.151.6)는 외부에 공유하지 않습니다.