

07. 기획·통계 — 진료통계

4주차 핵심: **모델 주소 한 줄(:11434 → :11500)** 만 공유 게이트웨이로 바꾸면, 추론 누출 차단·출력 길이 상한·모델명 정규화를 게이트웨이가 알아서 해 줍니다. 여러분은 프롬프트와 근거 데이터에만 집중하면 됩니다.

1. 내 앱 한눈에

- **아키텍처**: A형 RAG 챗봇 + 조회(C) 혼합. 자연어 질문을 받아 임베딩 검색으로 근거 줄을 찾고, 그 근거만 모델에 넣어 답하게 강제합니다. (분석문서 §과제매핑)
- **핵심 정체성**: “바이브(근거 없이 모델 단독) vs 하네스(임베딩 RAG + 출처)” **두 모드 비교**가 이 앱의 정체성입니다. 같은 질문을 두 방식으로 나란히 보여 주며, 숫자는 모델이 지어 내지 않고 Python이 집계한 값(`/api/aggregate`)·하드코딩 근거줄을 그대로 인용하게 합니다. (분석문서 §기능 2~3, 5)
- **구조**: 브라우저는 모델을 직접 부르지 않고 반드시 백엔드(FastAPI, :8000)를 거쳐 모델을 호출합니다. 그래서 우리가 바꿀 곳은 **백엔드 파일 한 곳(`app.py`)** 뿐입니다.

2. 바뀌는 것 — URL 한 줄

여러분 앱에서 모델 주소는 `app.py` 맨 위 설정 구역에 있습니다. **이미 게이트웨이(:11500)로 설정되어 있습니다.** (제출본 점검 시 패치 완료)

원래는 각자 띄운 모델 포트인 `:11434` (Ollama 기본 포트)를 가리키고 있었고, 이 앱은 **두 군데**에 주소가 박혀 있었습니다.

- `app.py:22` — 채팅·임베딩이 공통으로 쓰는 기준 주소 `OLLAMA_BASE`
- `app.py:277` — `/health` (연결 상태등)가 모델 목록을 따로 조회하는 주소

현재 상태 (둘 다 :11500 확인됨):

```
# app.py:22
OLLAMA_BASE = "http://121.138.151.6:11500" # ← 게이트웨이로 설정됨

# app.py:277 (/health 안)
r = await client.get("http://121.138.151.6:11500/api/tags") # ←
게이트웨이로 설정됨
```

원래(과거) 모습과 비교하면 이런 변경이 일어난 것입니다 (참고용 diff):

```
# app.py:22
- OLLAMA_BASE = "http://121.138.151.6:11434"
+ OLLAMA_BASE = "http://121.138.151.6:11500"

# app.py:277 (/health)
```

```
- r = await client.get("http://121.138.151.6:11434/api/tags")
+ r = await client.get("http://121.138.151.6:11500/api/tags")
```

주의: 이 앱은 주소가 두 곳(22행, 277행)에 있어, 한 줄만 고치면 본문 답변은 게이트웨이로 가도 `/health` 상태등은 옛 주소를 봅니다. **두 곳이 모두 :11500인지** 꼭 확인하세요. (지금은 둘 다 정상)

3. 확인 절차

순서대로 복붙하면 됩니다. (감염관리·통계 등 민감값 입력 금지 — 6번 안전수칙 참고)

1) 게이트웨이가 살아 있는지 먼저 확인

```
curl http://121.138.151.6:11500/health
```

→ 정상이면 상태 응답이 돌아옵니다. (응답이 없으면 강사에게 알리고 잠시 대기)

2) 백엔드(내 앱) 기동 — `app.py` 가 있는 폴더에서:

```
uvicorn app:app --host 0.0.0.0 --port 8000 --reload
```

3) 프론트(화면) 기동 — 같은 프로젝트 폴더에서 새 터미널 하나 더 열고:

```
python -m http.server 5500
```

그 다음 브라우저에서 `http://127.0.0.1:5500/index.html` 을 엽니다. (주의: `index.html` 을 파일로 직접 더블클릭하면 CORS로 막힙니다. 반드시 `:5500` 주소로 여세요. 프론트가 백엔드를 부르는 주소는 `index.html:473` 의 `BE = "http://127.0.0.1:8000"` 입니다.)

4) 내 앱 상태등 확인 — 백엔드가 게이트웨이를 잘 보는지:

```
curl http://127.0.0.1:8000/health
```

→ `"status":"ok"` , `"model_available":true` 면 게이트웨이·모델까지 정상입니다.

5) 대표질문 1개 테스트 (화면 입력창 또는 아래 명령):

```
curl -X POST http://127.0.0.1:8000/api/aggchat \
-H "Content-Type: application/json" \
-d '{"question":"소화기내과 외래 건수는?","bare":false}'
```

→ 기대 답: **84** (근거줄 “소화기내과 외래 합계 84”를 인용). `sources` 에 채택 근거가 함께 옵니다.

6) think(추론) 누출 없는지 확인 ★

- 이 모델(qwen3 계열)은 원래 `<think>...</think>` 같은 추론 과정을 답변에 흘릴 수 있습니다. 이 앱 코드에는 그걸 끄거나 지우는 처리가 **없습니다**.
- 하지만 **게이트웨이(:11500)가 `think:false` 를 자동 적용**하므로, 위 답변에 `<think>` , “사용자가 묻는 것은…” 같은 혼잣말이 **섞여 나오지 않으면 정상**입니다.

- 만약 추론 혼잡률이 보인다면 → 주소가 옛 포트(11434)로 남아 있을 가능성. 2번의 `app.py:22` · `app.py:277` 을 다시 확인하세요.

4. 개선 1~2가지 (제출 코드 기반)

개선 ① 주소를 한 곳에서만 관리 (하드코딩 → 환경변수) 지금은 같은 게이트웨이 주소가 `app.py:22` 와 `app.py:277` 두 군데에 따로 박혀 있어, 나중에 게이트웨이 주소가 바뀌면 한 곳만 고치고 다른 곳을 빠뜨리기 쉽습니다(`/health` 만 옛 주소를 보는 사고). `/health` 도 이미 만들어 둔 `OLLAMA_BASE` 를 재사용하도록 바꾸면 됩니다.

```
# app.py:277 (/health 안)
- r = await client.get("http://121.138.151.6:11500/api/tags")
+ r = await client.get(f"{OLLAMA_BASE}/api/tags")
```

(더 나아가면 22행을 `import os; OLLAMA_BASE = os.getenv("OLLAMA_BASE", "http://121.138.151.6:11500")` 로 바꿔 코드 수정 없이 주소를 교체할 수 있습니다.)

개선 ② 모델명 불일치로 인한 “준비 안 됨” 오폭시 대비 `/health` 는 `MODEL_NAME("qwen3.6:35b-a3b")` 이 게이트웨이의 모델 목록(`/api/tags`)에 **정확히 그 이름으로** 있어야 `status:ok` 를 줍니다. 게이트웨이가 모델명을 정규화하면 목록의 표기가 달라 항상 “degraded(모델 준비 안 됨)”로 뜰 수 있습니다. 본문 답변이 정상인데 상태 등만 빨갛다면, 모델명 정확 일치 대신 **목록이 비어 있지 않은지** 정도로 완화하는 것을 권장합니다. (분석문서 §결림돌 4)

참고: 출력 길이 상한(`num_predict`)도 이 코드엔 없지만, 게이트웨이가 상한을 자동 적용하므로 4주차에서는 따로 손대지 않아도 됩니다.

개선 ③ (★중요) 없는 진료과는 “확인되지 않습니다”로 거절 — 환각 차단 강사 실측 채점에 서 이 앱의 유일한 결함이 나왔습니다: “**안과 외래 건수는?**”(데이터에 없는 진료과)에 거절하지 않고 **무관한 일별 수치**(“01일 95, 02일 90”)를 안과 건수인 양 답했습니다. 이 앱의 존재 목적인 “숫자 환각 방지”를 정면으로 어기는 케이스입니다. 원인은 검색이 무엇이든 가장 가까운 줄을 끌어와 답에 쓰기 때문입니다. 권장 보완(택1·병행): - **진료과 화이트리스트 거절(가장 확실)**: 데이터에 있는 진료과 목록(소화기내과·순환기내과·외과·정형외과·신경외과 등)을 두고, 질문의 진료과가 목록에 없으면 **모델 호출 전에 “확인되지 않습니다”** 를 바로 반환. - **검색 임계값 상향 + 빈 컨텍스트 거절**: 유사도가 기준 미달이면 컨텍스트를 비우고, 시스템 프롬프트에 “근거가 비면 반드시 “확인되지 않습니다”를 강제. > 핵심 교훈(오늘의 하네스): **정확히 답하는 것보다 “모를 때 거절하는 규칙”을 코드로 박는 것이 품질을 가릅니다.** (거절 규칙이 확실한 감염관리 앱은 같은 평가에서 5.0/5로 무결했습니다.)

5. 안전수칙 (이 과제 특화)

- **진료통계 = 운영 민감수치**: 이 앱의 근거 데이터(`DOCS` , `app.py:60~80`)는 우리 병원 진료과별 집계로 추정됩니다. 개인정보는 아니지만 **실제 병원 운영수치**이므로, 실습·시연 때는 **더미(가짜) 숫자**로 바꿔 쓰고 실값을 외부로 캡처·공유하지 마세요.
- **환자정보·대외비 입력 금지**: 질문창에 환자 이름·차트번호·진단명 등 식별정보를 넣지 마세요. 통계 질문(건수·합계·최다/최소)만 다룹니다.
- **공유 GPU 1개 = 동시성 주의**: 게이트웨이 뒤 GPU는 한 대를 다 같이 씁니다. 이 앱은 채팅을 1건씩 순차 처리(`_chat_sem = Semaphore(1)` , `app.py:37`)하지만, **비교(⚖️) 기**

능은 한 질문을 두 번 호출하니 여러 명이 동시에 누르면 느려집니다. 천천히 한 명씩 시연 하세요.

- **상태등이 빨강다고 멈추지 말 것:** 모델명 표기 차이로 “degraded”가 떠도 답변은 정상일 수 있습니다(개선 ② 참고). 답이 깔끔하면 진행해도 됩니다.