

08. 간호부 — 간호지원

공유 게이트웨이(:11500) 위에서 내 앱을 운영급으로. 이 가이드는 **아직 앱 코드가 없는** 분을 위한 일반 안내입니다. 3주차 과제(간호 임상지원 RAG 챗봇)를 게이트웨이에 붙이는 표준 방법과, 코드가 없다면 출발선을 맞추는 법까지 한 장에 담았습니다. ⚠ **대외비 과목입니다.** 간호 프로토콜은 부서 내부 자료이며, 오늘 만드는 앱은 원격 모델을 호출하므로 실제 자료를 넣으면 외부로 나갑니다. **반드시 더미(가짜 교육용) 자료로만** 진행하세요.

1) 내 앱은 이런 모양 (A RAG 과제의 표준 구조)

간호지원 과제(08번)는 **A형 — 근거기반(RAG) 챗봇**입니다. “검사 전후 간호 알려줘”처럼 자연어로 물으면, 사내 간호 지침에서 **질문과 가까운 조각만 골라** 출처와 함께 답하는 앱입니다.

표준 구조는 항상 **3층**입니다. 모델은 절대 브라우저가 직접 부르지 않고, 항상 내 백엔드를 거칩니다.



- **프론트(index.html)**: 질문창과 답변창. **오직 내 백엔드(:8000)만** 부릅니다. 모델 주소(:11500)나 `ollama` 를 화면 자바스크립트에서 직접 부르면 안 됩니다(보안 사고).
- **내 백엔드(app.py:8000)**: 검색(임베딩)·근거 선별·모델 호출을 담당. 여기 한 곳만 게이트웨이를 압니다.
- **공유 게이트웨이(:11500)**: 모든 학생이 함께 쓰는 모델 서버. 추론 누출(think) 제거·답 길이 상한·모델명 정규화를 **자동으로** 처리합니다. 그래서 여러분은 프롬프트만 신경 쓰면 됩니다.

3주차에서 다룬 검색 RAG·바이브↔하네스 토글·4섹션(목적/검사 전/검사 후/주의사항) 형식이 모두 이 구조 위에서 동작합니다.

2) 바뀌는 것 — URL 한 줄

운영급으로 가는 변화는 **딱 한 줄**입니다. 백엔드 코드에서 모델 주소를 게이트웨이(:11500)로 두면 됩니다. 예전에 각자 띄우던 raw 주소는 `:11434` 였습니다.

```
# app.py 상단 - 모델 주소를 한 곳에 변수로 둡니다(권장)
OLLAMA_URL = "http://121.138.151.6:11500" # 지금: 공유 게이트웨이 (운영)
# OLLAMA_URL = "http://121.138.151.6:11434" # 예전: raw 주소(생각 누출·부하 위험)
```

이 변수 하나가 아래 세 가지 호출 전부에 그대로 쓰이게 합니다 — 주소를 바꿀 곳이 여기 하나뿐이라는 뜻입니다.

```
# 임베딩(검색용 벡터) → f"{OLLAMA_URL}/api/embeddings" model="bge-m3:latest"
# 생존 확인 → f"{OLLAMA_URL}/api/tags"
# 채팅(답변 생성) → f"{OLLAMA_URL}/api/chat"
model="qwen3.6:35b-a3b"
```

이미 :11500 으로 되어 있다면 **고칠 것이 없습니다**. 혹시 코드 어딘가에 :11434 나 주소가 직접 박혀 있으면, 그 11434 를 11500 으로 숫자 한 번만 바꾸면 됩니다. 그 외에는 손댈 코드가 없습니다.

```
- OLLAMA_URL = "http://121.138.151.6:11434"
+ OLLAMA_URL = "http://121.138.151.6:11500"
```

왜 이 한 줄이 운영급인가: :11434 는 생각(추론) 과정이 답에 섞여 나오거나, 여러 명이 동시에 쓰면 부하로 빈 답이 나오기 쉽습니다. :11500 은 게이트웨이가 think 제거·길이 상한 모델명 정규화를 한곳에서 처리합니다. 같은 모델, 다른 결과입니다.

3) 확인 절차

순서대로 4단계면 끝입니다.

(1) 게이트웨이가 살아있나 — /health 대신 먼저 게이트웨이 직접 점검

```
curl http://121.138.151.6:11500/api/tags
```

모델 목록(JSON)이 돌아오면 게이트웨이 정상입니다. 목록 안에 qwen3.6:35b-a3b (채팅)와 bge-m3 (임베딩)가 보이는지 눈으로 확인하세요. 비어 있거나 응답이 없으면 강사에게 알려 주세요(공유 서버 점검 필요).

(2) 앱 기동

백엔드를 8000번 포트로 띄웁니다(프론트가 8000을 바라봅니다).

```
uvicorn app:app --port 8000
```

그다음 백엔드 자체 상태를 확인합니다:

```
curl http://127.0.0.1:8000/health
# {"ok":true,"ollama":true,...} 처럼 ok와 ollama가 true면 정상
```

"ollama":true 면 내 백엔드 → 게이트웨이 연결까지 정상입니다. 이어서 브라우저에서 index.html 을 열어 채팅창이 뜨는지 봅니다.

(3) 대표 질문 1개 — 한번 돌려보기

화면 입력창(또는 명령줄)에 더미 자료 기반 질문 하나를 넣습니다.

수혈 검사 전후에 뭘 확인해야 해?

```
curl -N -X POST http://127.0.0.1:8000/api/chat \
-H "Content-Type: application/json" \
-d '{"question":"수혈 검사 전후에 뭘 확인해야 해?"}'
```

기대 동작: 답 위(또는 아래)에 **출처(예: “근거: 수혈”)** 가 함께 뜨고, “환자·혈액 이중확인 / 시작 15분 집중관찰 / 발열·오한 시 즉시 중단” 같은 근거 답이 흘러나옵니다.

(4) think(생각) 누출 없는지 확인

답변 안에 `<think>` 같은 태그나 “사용자가 ~을 물었으니 먼저...” 같은 **모델의 혼잣말(추론 과정)** 이 섞여 나오면 안 됩니다. 게이트웨이가 `think:false` 를 자동으로 걸어 주므로, 깔끔한 답만 나오는 것이 정상입니다. 만약 혼잣말이 보이면 주소가 `:11500` 인지부터 다시 확인하세요(`:11434` 로 되어 있으면 누출됩니다).

4) 아직 코드가 없다면 — 3주차 STEP0 캐치업으로 출발선 맞추기

08번은 코드 제출본이 없어 위 구조가 손에 없을 수 있습니다. 괜찮습니다. **3주차 개인 핸드아웃의 STEP 0**만 따라오면 같은 출발선에 섭니다.

- 참고 자료: 3주차 개인 PDF [lecture/3주차_강의_개인별/3주차_강의_08_간호지원.pdf](#) (또는 원본 [lecture/enrich_src/08_강의.md](#))
- 핵심: 공통 **STEP 0 기본코드**(`app.py` · `index.html`)를 띄우면, 위 “내 앱은 이런 모양” 3층 구조가 그대로 만들어집니다.

STEP 0 출발선 점검(3가지):

- 백엔드 실행 확인 — `curl http://127.0.0.1:8000/health` → `ok`
- 프론트 확인 — 브라우저에 `index.html` 이 뜨고 채팅창이 보임
- 채팅 동작 확인 — 아무 질문이나 보내면 백엔드를 거쳐 채팅 모델이 답함

⚠ STEP 0 코드를 만들 때부터 모델 주소를 처음부터 `:11500` 으로 두세요. 그러면 §2의 “URL 한 줄”은 이미 끝난 상태가 됩니다.

STEP 0이 되면 그 위에 3주차 STEP 1·2(진짜 검색 RAG·출처·바이브↔하네스 토글)를 얹어 나가면 됩니다. 오늘 4주차 목표는 거창한 신기능이 아니라, **STEP 0이 게이트웨이(:11500) 위에서 깔끔하게 도는 것을** 확인하는 데까지입니다.

STEP 1에 넣을 더미 자료는 3주차 핸드아웃의 **가짜 8조각**(EGD·대장내시경·수혈·조영 CT·MRI·채혈·심전도·복부초음파)을 그대로 쓰세요. 전부 교육용 가짜 예시이며 실제 프로토콜이 아닙니다.

5) 안전수칙 (대외비 — 가장 중요)

- 실제 임상정보 입력 절대 금지** — 환자명·등록번호·주민번호·“○○호 △△△”(병실+이름), 그리고 **실제 간호 프로토콜 전문**을 입력창이나 코드(`DOCS`)에 넣지 마세요. 오늘 만드는

앱은 원격 모델(:11500)을 호출하므로 **넣은 내용은 외부로 나갑니다.**

- **더미(가짜)만 사용** — 검색 자료는 3주치의 가짜 8조각처럼 **비식별 교육용 예시로만**. 실제 사례·내부 통계·실명은 금지입니다.
- **외부(상용) 모델 전송 금지** — ChatGPT·Claude 등 사내 게이트웨이 밖의 외부 모델에 간 호 자료를 붙여 넣지 마세요. 호출 대상은 **오직 사내 게이트웨이**
<http://121.138.151.6:11500> 뿐입니다.
- **프론트는 백엔드만** — **[index.html](#)** 에서 **:11500** 이나 **ollama** 를 직접 부르지 마세요. 모든 모델 호출은 내 백엔드(:8000)를 거칩니다(보안·CORS 사고 방지).
- **공유 GPU 1개, 동시성 주의** — 게이트웨이 뒤 GPU는 모두가 함께 씁니다. 여러 명이 동시에 긴 질문을 던지면 느려집니다. 한 번에 한 질문씩, 답이 끝나면 다음 질문을. 테스트가 끝나면 띄운 **uvicorn** 을 내려(Ctrl+C) 불필요한 부하를 남기지 마세요.
- **모델 답은 참고용** — 실제 간호 적용은 반드시 부서 프로토콜·담당자 확인을 거치세요.