

10. 진료협력센터 — 병원검색

4주차 한 줄 컨셉: “공유 게이트웨이(:11500) 위에서 내 앱을 운영급으로.” 각자 모델을 띄울 필요 없이, 게이트웨이가 추론 누출(think) 차단·답변 길이 상한·모델명 자동 보정을 한곳에서 처리한다. 내 앱은 **모델 주소 한 줄만** 가리키면 끝.

⚠ 이 가이드는 '일반형'입니다. 이번 과제는 **실제 코드가 제출되지 않아**(아래 ★ 참고) 본인 코드의 정확한 줄번호 대신 **표준 구조 기준**으로 안내합니다. 3주차에 만든 코드를 그대로 쓰시면 됩니다.

★ 먼저 — 제출 파일 문제부터 (1분, 꼭 읽기)

이번에 제출된 파일은 **병원검색.lnk** 한 개뿐입니다. **.lnk** 는 윈도우 ‘바로가기’(실제 폴더를 가리키는 화살표)일 뿐, **안에 코드가 없습니다**. 그래서 게이트웨이에 붙일 대상이 없는 상태입니다.

해야 할 일 — 실제 프로젝트 폴더를 다시 제출:


1. 바로가기(**병원검색.lnk**)를 **더블클릭**하면 열리는 그 **폴더**가 진짜 프로젝트입니다. (보통 **app.py** · **index.html** 같은 파일이 들어 있는 폴더)
2. 그 **폴더 전체**를 압축합니다.
 - 윈도우: 폴더에서 **마우스 오른쪽** → **압축(ZIP)** → “**압축 폴더로 보내기**”
 - 맥: 폴더에서 **오른쪽** → “**압축**” → **.zip** 생성
3. 만들어진 **병원검색.zip** 을 제출합니다. (**.lnk** 말고 **.zip**)

🔍 **확실히 구분하는 법**: 파일 크기가 수 KB(2KB 안팎)면 거의 **.lnk** (바로가기) 입니다. 실제 코드 폴더는 보통 수십 KB~수 MB입니다. 압축 후 크기가 너무 작으면 또 바로가기만 담긴 것이니 1번부터 다시 하세요. 🚫 **바로가기(.lnk) 재제출 금지** — 받는 쪽 PC에서는 그 경로가 없어 아무것도 열리지 않습니다. 반드시 **폴더 자체를 압축**하세요.

아래 1~5는 재제출 후(또는 본인 PC에 코드가 있는 상태에서) 따라오면 됩니다.

1. 내 앱은 이런 모양 (표준 구조)

- **아키타입: C(조회·검색) 형**. 진료협력센터의 **협력 병원 디렉토리**(병원명·지역·구분·병상·전화 등)를 **검색·필터**하고, “조건을 말로 물으면” 관련 병원을 찾아 답하는 보조 챗을 엮는 구조입니다.
- **3단 구조 (이게 핵심)**:



- 읽는 법: 화면(`index.html`)은 내 백엔드(`:8000`)만 부릅니다. 모델이 필요하다면 백엔드가 게이트웨이(`:11500`)로 대신 호출합니다.
- 절대 규칙: 브라우저(HTML·자바스크립트)에서 모델 서버를 직접 부르지 않습니다. 모델 호출은 오직 백엔드 안에서만. (3주차 '프론트/백엔드 분리'와 같음)

즉 4주차에 바뀌는 건 딱 한 군데입니다. 백엔드가 모델을 부르던 주소를 raw 포트(`:11434`)에서 게이트웨이(`:11500`)로 바꾸는 것. 화면 코드·검색 로직은 그대로입니다.

2. 바뀌는 것 — URL 한 줄

백엔드(`app.py`) 상단에서 모델 주소를 담아 둔 변수 한 줄을 찾아, 포트 숫자만 `11500` 으로 둡니다. IP(`121.138.151.6`)는 그대로입니다.

`app.py` 상단 — 표준 형태 (이렇게 두면 됩니다)

```
OLLAMA_URL = "http://121.138.151.6:11500"
```

- 만약 지금 코드가 `:11434` (각자 띄우던 raw 포트)로 돼 있다면, 아래처럼 그 줄만 고칩니다.

```
- OLLAMA_URL = "http://121.138.151.6:11434"
```

```
+ OLLAMA_URL = "http://121.138.151.6:11500"
```

- 채팅·임베딩을 경로까지 붙여서 쓰는 코드라면(아래처럼 생겼다면) 두 줄 다 포트만 바꿉니다.

```
- OLLAMA_URL = "http://121.138.151.6:11434/api/chat"
```

```
- EMBED_URL = "http://121.138.151.6:11434/api/embeddings"
```

```
+ OLLAMA_URL = "http://121.138.151.6:11500/api/chat"
```

```
+ EMBED_URL = "http://121.138.151.6:11500/api/embeddings"
```

찾기 팁(비개발자용): 코드 편집기에서 `11434` 로 검색(맥 `Cmd+F` / 윈도우 `Ctrl+F`)하면 바꿔야 할 줄이 바로 보입니다. 나오는 `11434` 를 전부 `11500` 으로만 바꾸세요. 모델명·옵션은 손대지 않습니다. `qwen3.6:35b-a3b` (채팅)·`bge-m3:latest` (임베딩) 같은 모델명, `num_predict` · `think` 같은 옵션은 게이트웨이가 알아서 보정합니다. URL 포트 하나만 신경 쓰면 됩니다.

3. 확인 절차

(1) 게이트웨이가 살아있나 — `/health`

먼저 공유 게이트웨이가 켜져 있는지 확인합니다. 터미널에 그대로 붙여넣으세요.

```
curl http://121.138.151.6:11500/health
```

- 정상이면 `ok` (또는 짧은 상태 JSON)가 돌아옵니다.

- 응답이 없으면 게이트웨이가 꺼졌거나 네트워크 문제입니다. 강사에게 알려세요. (이게 안 되면 챗봇도 당연히 안 됩니다.)

(원하면 모델 목록도 확인할 수 있습니다.)

```
curl http://121.138.151.6:11500/api/tags
```

(2) 내 앱 기동 (백엔드 → 프론트)

프로젝트 폴더에서 백엔드를 먼저 띄웁니다. (실행 명령은 본인 코드 형태에 맞춰 둘 중 하나)

FastAPI 형태라면

```
python -m uvicorn app:app --port 8000
```

단일 파일(app.py가 직접 서버를 띄우는) 형태라면

```
python app.py
```

백엔드가 댄는지 확인:

```
curl http://127.0.0.1:8000/health
```

`{"ok": true}` 류 응답이 오면 정상입니다. 이어서 데이터도 확인:

```
curl http://127.0.0.1:8000/api/data
```

협력 병원 목록(더미)이 JSON으로 보이면 데이터 서빙 정상입니다. 그다음 브라우저에서 화면(`index.html` 또는 `http://127.0.0.1:8000`)을 엽니다.

(3) 대표 질문 1개

챗 입력창에 아래를 넣어봅니다.

거제에서 야간투석 되는 곳 알려줘

기대 동작: 관련 병원 조각(예: 거제 카타병원 — 야간투석)을 찾아 출처(병원명·전화)와 함께 간결히 답합니다. 무관한 질문(“수영장 어디”)에는 “자료에서 확인되지 않습니다”라고 답하면 정상입니다.

(4) think(생각 과정) 누출 없는지 확인

- 답변에 `<think>` ... `</think>` 같은 모델의 혼잣말(추론 과정)이 그대로 보이면 안 됩니다. 게이트웨이(`:11500`)를 쓰면 이 부분이 자동으로 걸러져 깔끔한 최종 답만 나옵니다.
- 혹시 `<think>` 가 보이거나 답이 비어 나온다면, 십중팔구 주소가 다시 `:11434 (raw)` 로 남아 있는 것입니다. 2번 절의 `OLLAMA_URL` 줄을 다시 확인하세요.
- 마지막으로 브라우저 Network 탭에 `:8000` 호출만 보이고 `:11434` · `:11500` 직접 호출이 없으면 프론트/백엔드 분리도 정상입니다.

4. 아직 코드가 없다면 — 3주차 핸드아웃 STEP0으로 출발선 맞추기

★의 재제출과 별개로, 본인 PC에서 앱을 띄울 수 있어야 위 3번을 해볼 수 있습니다. 코드가 없거나 3주차 숙제를 못 끝냈다면 아래로 출발선을 맞추세요.

1. 3주차 개인 핸드아웃을 펴세요: 3주차_강의_개인별/3주차_강의_10_진료협력.pdf
2. 거기 STEP 0 — 기본코드(공통 app.py · index.html)를 그대로 띄웁니다. 이게 “검색 화면 + 백엔드(:8000)”의 출발점입니다.
3. 출발선 점검 2가지:
 - curl http://127.0.0.1:8000/health → {"ok": true} 류 응답 (백엔드 정상)
 - 브라우저에서 http://127.0.0.1:8000/api/data → 협력 병원 8개가 JSON으로 보임 (데이터 서빙 정상)
4. 이 둘이 보이면 출발 준비 끝. 이제 2번(URL 한 줄)으로 가서 모델 주소만 :11500 으로 두고, 3번(확인 절차)을 진행하면 됩니다.

3주차 핸드아웃에는 “조건을 말로 물으면 관련 병원을 찾아 답하는 보조 챗(키워드 매칭 또는 임베딩 RAG)” 만드는 프롬프트가 단계별로 들어 있습니다. 4주차는 그 위에 **모델 주소만 게이트웨이로 바꾸는** 작업이라, 3주차 결과물이 있으면 5분이면 끝납니다.

★ 다시 한번 — 평가·피드백을 받으려면 .lnk 가 아니라 실제 폴더(.zip)를 재제출하세요. 위 ★ 절차 참고.

5. 안전수칙 (이 과제 특화)

- **전부 더미·비식별만.** 협력 병원 디렉토리는 **가짜 데이터**로 실습합니다(병원명·전화·병상 모두 더미, 예: 055-000-1000). **실제 협력기관 명단**을 코드·질문에 넣지 마세요.
- **환자정보(PHI)·대외비 입력 금지.** 챗 입력창에 환자 이름·등록번호·진단명·실제 의뢰 내용을 절대 넣지 않습니다. 질문은 “거제 투석 병원” 처럼 **조건 단위**로만.
- **질병·병원 직접 연계 금지.** 특정 질병명을 특정 병원에 바로 붙이지 말고, **구분(범주: 투석·호스피스·격리/감염·재활·요양)** 으로만 안내합니다.
- **분리 강제.** 화면(index.html)은 http://127.0.0.1:8000 만 호출합니다. 모델 서버(121.138.151.6)·ollama 를 프론트에서 **직접 부르지 않습니다** — 백엔드가 대신 호출.
- **공유 GPU는 하나뿐 — 동시성 주의.** :11500 뒤의 모델 서버는 **여러 명이 함께 쓰는 GPU 1대**입니다. 긴 질문을 연달아 몰아넣지 말고, 답이 끝난 뒤 다음 질문을 보내세요. 여러 명이 동시에 물리면 모두 느려집니다(서버를 탕하지 말 것).
- **모델 서버 주소·모델명 외부 공유 금지.** 121.138.151.6:11500 , 모델명 (qwen3.6:35b-a3b · bge-m3:latest)은 교육용이며 외부로 공유하지 않습니다.