

03. 의공팀 — 의료기기 · 공유 API 붙이기 프롬프트

대상: 의료기기 수리 매뉴얼 챗봇(주입펌프 DI-2200P) · RAG 근거검색 + 리콜 로트 대조 + 자격 고지 방식: 코드를 손으로 고치지 않습니다. 아래 프롬프트를 **Claude Code에 그대로 붙여넣어** AI에게 시킵니다.

① 한 줄 목표

내 챗봇이 **공유 게이트웨이(http://121.138.151.6:11500)** 를 쓰도록 주소 두 줄(채팅·임베딩)을 바꾸고, 이제 필요 없어진 `think·num_predict` 처리 코드를 정리하고, “자료에 없으면 확인되지 않습니다” 거절 규칙을 시스템 프롬프트에 확인·추가한다.

② 복붙 프롬프트 (이 블록을 그대로 Claude Code에 붙여넣기)

너는 내 파이썬 프로젝트를 고쳐주는 개발 도우미야. 아래 작업을 순서대로 해줘.
이 앱은 의료기기(주입펌프 DI-2200P) 수리 매뉴얼 챗봇이고, RAG(근거검색)와 리콜 로트 대조 기능이 있어. 채팅과 임베딩을 둘 다 호출한다는 점이 중요해.

[1] 모델 주소를 공유 게이트웨이로 변경

- 본인 앱의 `app.py` 상단(대략 19~20행)에 있는 두 줄을 찾아줘:

```
OLLAMA_URL = "... (채팅 주소) /api/chat"
```

```
EMBED_URL = "... (임베딩 주소) /api/embeddings"
```

- 두 줄의 호스트·포트를 모두 `http://121.138.151.6:11500` 으로 바꿔줘. 결과는 정확히 이렇게:

```
OLLAMA_URL = "http://121.138.151.6:11500/api/chat"
```

```
EMBED_URL = "http://121.138.151.6:11500/api/embeddings"
```

- `:11434` 나 다른 주소로 남아 있는 곳이 파일 어디에도 없는지 전체를 한 번 더 확인해 줘. 채팅과 임베딩 둘 다 `:11500` 이어야 해.

- 바로 아래에 있는 모델명 변수(`MODEL`, `EMBED_MODEL` 등, 예: `qwen3.6`, `bge-m3`)는 게이트웨이가 알아서 정규화하니까 절대 건드리지 마.

[2] 이제 필요 없어진 `think / num_predict` 처리 코드 정리

- 게이트웨이가 `think:false` 와 `num_predict` 상한을 자동으로 처리해줘. 그래서 앱 쪽에서 그걸 직접 다루던 코드는 더 이상 필요 없어.

- 채팅·임베딩을 호출하는 요청 `payload`(보통 `requests.post(...)`의 `json=...` 부분)에서 다음을 찾아 정리해줘:

- `"think": true/false` 옵션을 보내는 부분 → 제거

- `options` 안의 `"num_predict"` 로 길이를 강제로 제한하던 부분 → 제거

- 응답에서 `<think> ... </think>` 같은 모델 혼잣말(추론 텍스트)을 잘라내려고 만든 후처리 코드가 있으면 → 제거 (게이트웨이가 이미 걸러줌)

- 확실치 않으면 지우기 전에 "이 줄을 지워도 되는지" 나한테 먼저 물어봐. 관련 코드가 원래 없었다면 "없음"이라고만 알려줘.

[3] 거절 규칙(안전 고지)을 시스템 프롬프트에 확인·추가

- 본인 앱의 시스템 프롬프트(모델에게 역할을 지시하는 문자열, 보통 SYSTEM_PROMPT 나 messages의 role:"system" 부분)를 찾아줘.
- 거기에 아래 규칙이 이미 있는지 확인하고, 없으면 자연스럽게 추가해줘(한국어로):
 - "제공된 매뉴얼·자료(검색된 근거)에 없는 내용은 지어내지 말고 '자료에 없어 확인되지 않습니다'라고 답한다."
 - "이 답변은 자료 안내용이며 시술·수리 지시가 아니다. 실제 분해·내부 수리는 자격 기술자/제조사 서비스 대상임을 답변 끝에 고지한다."
 - "환자정보·실제 시리얼/로트 번호는 다루지 않는다."
- 원래 있던 출처 표기(근거: ... p.00)와 자격 고지 문구는 그대로 유지해줘. 새 규칙과 충돌하지 않게.

[4] 마무리

- 위에서 바꾼 파일과 줄을 요약해서 보여주고, 문법 오류가 없는지 확인해줘.
- 실행 방법(백엔드 uvicorn, 프론트 http.server)은 바꾸지 말고 그대로 뒤.

③ 이 프롬프트가 실제로 바꾸는 것

- **주소 두 줄**: 채팅(OLLAMA_URL)·임베딩(EMBED_URL)이 모두 공유 게이트웨이 :11500 을 가리키게 됩니다. (이 앱은 임베딩도 쓰므로 한 줄이 아니라 두 줄입니다.)
- **군더더기 정리**: think 옵션·num_predict 길이 제한·`<think>` 잘라내기 후처리가 사라 집니다. 게이트웨이가 대신 처리하므로 코드가 단순해집니다.
- **거절 규칙 명시**: 검색된 자료에 없으면 “확인되지 않습니다”라고 답하고, 자격 고지를 붙이 는 규칙이 시스템 프롬프트에 확실히 들어갑니다.
- **안 바뀌는 것**: 모델명(qwen3.6, bge-m3)과 실행 방식은 그대로입니다.

④ 붙인 뒤 확인

1. 게이트웨이 살아있나 — 터미널에서:

```
curl http://121.138.151.6:11500/health
```

정상 응답이 오면 게이트웨이 준비 완료입니다.

2. 앱 기동 — 터미널 2개(본인 앱 폴더에서):

```
python -m uvicorn app:app --port 8000      # 터미널 1 (백엔드)
python -m http.server 5500                 # 터미널 2 (프론트)
```

브라우저에서 `http://127.0.0.1:5500/index.html` 접속 → 상단 연결 상태가 초록이면 정상.

3. 대표질문 1개 — 채팅창에 입력:

E15 오류가 뜨는데 어떻게 하나요?

기대: “E15 압력센서 신호 불안정 → 캘리브레이션 필요(자격 기술자 전용)” 취지 안내 + 출처 칩(근거: ... p.78) + 자격 고지 한 줄. 답변에 `<think>` 같은 혼잣말이 안 보이면 성공입니다.

⑤ 안전

- **더미·비식별 값만 사용:** 질문·리콜 대조 입력에 환자 이름·환자번호·실제 시리얼/로트를 넣지 마세요. 실습은 더미 로트(예: L2401, L2402)만.
- **안내용이지 수리 지시 아님:** 챗봇은 자료에 있는 내용만 안내합니다. 실제 분해·내부 수리는 자격 기술자/제조사 서비스 대상입니다. 답변 끝 자격 고지를 반드시 함께 읽으세요.
- **거절 규칙 확인:** 자료에 없는 내용을 지어내지 않고 “확인되지 않습니다”라고 답하는지 위②[3] 규칙이 시스템 프롬프트에 들어갔는지 꼭 확인하세요.
- **공유 GPU 1개:** 모두가 GPU 하나를 같이 씁니다. 답이 끝난 뒤 다음 질문을 보내세요(긴 질문 연달아 금지).