

05. 약제부 — hira비급여조회 · 공유 API 붙이기 프롬프트

① 한 줄 목표

내 비급여조회 앱의 챗봇을 **공유 게이트웨이(:11500)**에 붙이고, 게이트웨이가 대신 처리해 주는 불필요한 코드를 정리하며, “자료에 없으면 답하지 않는” 거절 규칙을 시스템 프롬프트에 넣는다. (손으로 고치지 말고 아래 프롬프트를 Claude Code에 그대로 붙여넣는다.)

② 복붙 프롬프트 (Claude Code에 그대로 붙여넣기)

너는 내 파이썬 Flask 앱(hira 비급여조회 챗봇)을 수정하는 코딩 도우미야.
앱은 app.py 단일 파일 + templates/index.html 로 되어 있고,
챗봇은 브라우저가 아니라 백엔드(Flask)가 모델 서버로 대신 호출(프록시)하는 구조야.
아래 4가지를 순서대로, 최소 변경으로만 처리해줘. 각 단계마다 무엇을 바꿨는지 한 줄로 알려줘.

1) 모델 주소를 공유 게이트웨이로 고정

- 본인 앱의 모델 주소 변수(OLLAMA_URL, app.py 상단)를 찾아줘.
- 값이 "http://121.138.151.6:11500" 이면 그대로 두고 "이미 게이트웨이로 설정됨"이라고만 알려줘.
- 만약 포트가 11434 등 다른 값이면 IP(121.138.151.6)는 그대로 두고 포트만 11500으로 바꿔줘.
- 챗봇 호출부와 모델목록 조회부가 이 변수를 그대로 쓰는지도 확인해줘.

2) 모델명은 건드리지 마

- 채팅 모델명 변수(CHAT_MODEL, 예: "qwen2.5:14b-instruct-q4_K_M")는 절대 바꾸지 마.
- 게이트웨이가 모델명을 알아서 보정해 주니 그대로 두면 돼.

3) 게이트웨이가 대신 처리하므로 불필요해진 코드 정리

- 게이트웨이(:11500)가 추론 누출 차단(think:false 강제)과 답변 길이 상한을 서버에서 처리해줘.
- 그러니 본인 앱이 모델 호출 payload에 직접 넣던 다음 것들은 정리해도 돼:
 - options 안의 num_predict(답변 길이 상한) 같은 값
 - think 관련 옵션이나, 응답에서 <think>...</think>를 잘라내려고 직접 만든 후처리 코드
- 다만 이건 "있으면 정리, 없으면 그냥 둔다" 수준으로만. 있는지 먼저 보여주고, 지워도 앱이 동작하는지 확인한 뒤 지워줘.
- 스트리밍 여부(stream)나 타임아웃 등 동작에 필요한 옵션은 건드리지 마.

4) 거절 규칙을 시스템 프롬프트에 확인·추가

- 챗봇에 넘기는 시스템 프롬프트(안내 역할 지시문)를 찾아줘.
- 아래 취지의 규칙이 이미 있는지 확인하고, 없으면 자연스럽게 추가해줘:
"제공된 비급여 데이터/검색 결과에 없는 내용은 지어내지 말고

'자료에 없어 확인되지 않습니다'라고 답한다. 특정 병원의 정확한 금액을 단정하지 말고, 필요하면 답변에 [SEARCH:키워드] 형식으로 검색 버튼을 넣어 안 내한다."

- 기존 [SEARCH:키워드] 규칙(답변에 검색 버튼을 넣는 기능)은 그대로 유지해줘.

작업 후: 바뀐 줄만 diff로 요약하고, 앱을 실행하는 방법(포트 포함)을 한 줄로 알려줘.

③ 이 프롬프트가 실제로 바꾸는 것

- 모델 주소를 공유 게이트웨이 :11500 으로 고정한다 (이미 되어 있으면 확인만).
- 모델 호출에서 직접 넣던 num_predict (길이 상한) <think> 후처리 등 게이트웨이가 대신 하는 코드를 정리한다.
- 시스템 프롬프트에 “자료에 없으면 확인되지 않습니다” 거절 규칙을 넣는다 (환자·금액 지어내기 방지).
- 모델명(qwen2.5:14b...)과 [SEARCH:키워드] 기능은 그대로 둔다 — 게이트웨이가 모델명을 보정해 준다.

④ 불인 뒤 확인

1) 게이트웨이가 살아있나

```
curl http://121.138.151.6:11500/health
```

2) 앱 기동 (run.sh가 .env를 읽고 python3 app.py 실행)

```
cd hira-app/hira-app
```

```
./run.sh
```

- 접속 포트는 8080이다. run.sh 는 5000이라고 안내하지만 실제 기본값은 http://localhost:8080 . (5000을 쓰려면 PORT=5000 ./run.sh)
- 대표 질문 1개를 챗봇에 넣어본다: “창원에서 무릎 인공관절 수술 비급여 가격이 궁금해요”
 - 기대: 3~5문장으로 간결히 답하고, 답변 안에 [SEARCH:인공관절] 같은 검색 버튼이 생긴다.
 - 답변에 <think> ... </think> 같은 생각 과정이 보이거나 답이 비어 있으면, 주소가 :11434 로 돌아간 것 → ①을 다시 확인.

⑤ 안전

- 더미·비식별만. 챗봇 입력창에 환자 이름·등록번호·진단명 같은 개인정보는 절대 넣지 않는다. 질문은 “OO 수술 비급여 가격대”처럼 항목 단위로만.
- 거절 규칙 유지. 자료(검색 결과)에 없는 금액을 단정하지 말고 “확인되지 않습니다”로 답하게 둔다.
- 데이터·키 반출 금지. MOCK_DATA · cache.pkl (공공데이터)과 .env 의 심평원 API 키를 외부(메신저·메일)로 보내지 않는다.
- 공유 GPU는 1대. 여러 명이 동시에 첫 기동/긴 질문을 몰지 말고 순서대로. 느려도 잠시 기다린다.