

06. 인사 — 복리후생 · 공유 API 붙이기 프롬프트

① 한 줄 목표

내 경조 복리후생 챗봇(A RAG)이 모델을 **공유 게이트웨이**

(**`http://121.138.151.6:11500`**) 로만 부르게 바꾸고, 게이트웨이가 대신 처리해 주는 불필요한 코드를 정리한다. (손으로 고치지 말고 아래 프롬프트를 Claude Code에 그대로 붙여넣어 시킨다.)

② 복붙 프롬프트 (Claude Code에 그대로 붙여넣기)

너는 내 FastAPI 기반 경조 복리후생 챗봇(A RAG) 코드를 수정하는 개발 도우미야.
아래 작업을 순서대로 하고, 끝나면 무엇을 바꿨는지 요약해줘.

[사전 확인]

- 먼저 본인 앱의 백엔드 코드(`app.py` 등)에서 모델 서버 주소가 들어간 줄을 전부 찾아줘. "`121.138.151.6`", "`11434`", "`11500`", "`ollama`", "`/api/chat`", "`/api/embeddings`" 같은 문자열이 있는 줄이 대상이야.

[작업 1] 모델 주소를 공유 게이트웨이로 변경

- 본인 앱의 모델 주소 줄(예: `OLLAMA_URL` 같은 변수)의 포트를 `11434` → `11500` 으로 바꿔줘. IP(`121.138.151.6`)는 그대로 뒀. 즉 최종값이 "`http://121.138.151.6:11500`" 이 되게 해줘.
- 만약 주소가 여러 군데 하드코딩돼 있으면, 파일 위쪽에 `OLLAMA_URL = "http://121.138.151.6:11500"` 변수를 하나 만들고 채팅 호출(`/api/chat`)과 임베딩 호출(`/api/embeddings`) 모두 이 변수를 f-string으로 가져다 쓰게 통일해줘.
- 채팅/임베딩 모델명(예: `qwen3.6:35b-a3b`, `bge-m3:latest`)은 그대로 뒀. 게이트웨이가 실제 모델로 알아서 보정해주니까 건드리지 마.

[작업 2] 게이트웨이가 대신 처리하는 코드 정리

- 게이트웨이(`:11500`)가 추론 과정 차단(`think:false`), 답변 길이 상한, 모델명 보정을 자동으로 해줘. 그래서 본인 앱의 모델 호출 `payload`에 아래 옵션이 박혀 있으면 지워줘:
 - "`think`": `false` 같은 `think` 관련 옵션
 - `options` 안의 "`num_predict`" (답변 길이 상한) 설정
 - 응답에서 `<think>...</think>` 를 정규식으로 잘라내던 후처리 코드단, 이 옵션들을 지워도 나머지 로직(RAG 검색, 출처 표시)이 깨지지 않게 조심해서 지워줘. 확신이 안 서는 줄은 지우지 말고 나한테 물어봐줘.

[작업 3] 거절 규칙(환각 방지) 확인·추가

- 본인 앱의 시스템 프롬프트(모델에게 역할을 지시하는 문자열)를 찾아줘.

- 거기에 아래 규칙이 없으면 자연스럽게 추가해줘. 이미 비슷한 문장이 있으면 중복 추가하지 말고 그대로 뒤:
"제공된 경조표 근거에 없는 금액·휴가일수는 지어내지 말 것.
근거에서 값을 찾을 수 없으면 '자료에 없어 확인되지 않습니다 - 인사팀에 문의하세요'라고 답할 것. 추정·계산으로 숫자를 만들지 말 것."
- 답변은 검색된 표 조각의 값을 그대로 옮기고, 가능하면 어느 줄을 근거로 썼는지 출처를 함께 보여주는 기존 동작을 유지해줘.

[마무리]

- 바꾼 파일과 줄을 요약하고, 지운 코드가 있으면 왜 지웠는지 설명해줘.
- 프론트(index.html 등)에서 모델(11434/11500/ollama)을 직접 부르는 코드가 있으면 경고만 해줘(백엔드를 거쳐야 하니까). 임의로 큰 구조를 바꾸지는 마.

③ 이 프롬프트가 실제로 바꾸는 것

- 모델 호출 주소의 포트를 :11434 (각자 raw) → :11500 (공유 게이트웨이)으로 통일한다. IP와 모델명은 그대로.
- 코드에 박혀 있던 think:false · num_predict · <think> 잘라내기 후처리를 정리한다 — 이제 게이트웨이가 한곳에서 처리하기 때문.
- 시스템 프롬프트에 “근거에 없으면 지어내지 말고 '확인되지 않습니다'로 답하라”는 거절 규칙을 확인·보강한다(경조금 환각 방지).
- 프론트에서 모델을 직접 부르는 위험 코드가 있으면 경고로 알려준다.

④ 붙인 뒤 확인

1. 게이트웨이 생존 확인 — 터미널에 그대로:

```
curl http://121.138.151.6:11500/health
```

ok (또는 짧은 상태 JSON)가 오면 정상. 응답 없으면 강사에게 알린다.

2. 앱 기동 — 앱 폴더에서 백엔드를 띄운다(python3 app.py 또는 uvicorn app:app --port 8000). 127.0.0.1:8000 대기 메시지가 뜨면 브라우저로 index.html 을 연다.
3. 대표 질문 1개 — 입력창에 “부모 사망 휴가 며칠인가요?” → 표 값 그대로 “휴가 5일”처럼 답하고, 답변에 <think>...</think> 같은 사고 과정이 보이지 않으면 성공. (만약 <think> 가 보이거나 답이 비면 주소가 다시 :11434 로 돌아간 것 — 작업 1을 다시 확인.)

⑤ 안전 (더미·비식별만, 거절 규칙)

- 개인 경조내역 입력 금지. 직원 이름·사번·실제 신청 사유는 넣지 않는다. 질문은 “부모 사망 휴가 며칠?”처럼 항목 단위로만. 이름이 필요하면 “직원 A” 같은 더미로.
- 경조표는 교육용 더미만. DOCS 에 실제 사규 경조표(대외비 가능)를 그대로 넣어 외부로 보내지 않는다. 실데이터는 추후 내부망에서만.
- 거절 규칙 필수. 표에 없는 금액·휴가일수는 지어내지 말고 “자료에 없어 확인되지 않습니다 — 인사팀 문의”로 답하게 한다(작업 3). 경조금은 민감한 숫자라 환각이 특히 위험하다.
- 프론트에서 모델 직접 호출 금지. HTML/JS에서 11434 · 11500 · ollama 를 직접 부르지 않는다. 모델 호출은 오직 백엔드(:8000)를 거친다(보안·CORS).

- **공유 GPU 1대 — 동시성 주의.** 답변이 느리면 잠시 기다린다. 게이트웨이 주소는 외부에 공유하지 않는다.