

08. 간호부 — 간호지원 · 공유 API 붙이기 프롬프트

⚠ **대외비 과목입니다.** 이 앱은 원격 모델(:11500)을 호출하므로, 입력창·코드에 넣은 내용은 외부로 나갑니다. **반드시 더미(가짜 교육용) 자료로만** 진행하세요. 실제 임상정보·간호 프로토콜 전문은 절대 금지입니다.

① 한 줄 목표

내 간호지원 RAG 챗봇의 모델 호출을 **공유 게이트웨이(<http://121.138.151.6:11500>)** 로 바꾸고, 게이트웨이가 대신 처리하는 코드는 정리하고, “자료에 없으면 확인되지 않습니다” 거절 규칙을 시스템 프롬프트에 확인·추가한다. 손으로 고치지 않고 **Claude Code에 아래 프롬프트를 붙여넣어** AI가 하게 시킨다.

② 복붙 프롬프트 (Claude Code에 이걸 그대로 붙여넣으세요)

너는 내 간호지원 RAG 챗봇(A형 근거기반 챗봇)의 코드를 고치는 조수야.

내 앱은 [프론트 `index.html`] → [내 백엔드 `app.py(:8000)`] → [모델 서버] 3층 구조이고,

백엔드만 모델 서버를 호출해. 아래 작업을 순서대로 하되, 확실치 않으면 먼저 물어봐.

1) 모델 주소를 공유 게이트웨이로 통일

- 본인 앱 백엔드에서 모델 서버 주소가 적힌 줄(예: `OLLAMA_URL` 같은 변수, 또는 주소가 직접 박힌 곳)을 전부 찾아줘. 특히 `:11434` 나 `:11500` 이 들어간 줄.
- 그 주소를 모두 `http://121.138.151.6:11500` 로 바꿔줘.
- 가능하면 주소를 파일 상단 변수 한 곳(예: `OLLAMA_URL`)에 두고, 임베딩 호출(`/api/embeddings, bge-m3:latest`), 생존확인(`/api/tags`), 채팅 호출(`/api/chat, qwen3.6:35b-a3b`) 세 군데가 전부 그 변수를 쓰게 정리해줘.
- 프론트(`index.html`)에서 `:11500` 이나 `ollama` 를 직접 부르는 코드가 있으면 그건 보안 위반이야. 지우고 반드시 내 백엔드(`:8000`)만 부르게 바꿔줘.

2) 게이트웨이가 대신 해주는 코드 정리

- 이제 게이트웨이가 `think` 제거·답 길이 상한·모델명 정규화를 자동으로 해줘. 그래서 백엔드에서 아래 것들이 있으면 불필요하니 찾아서 정리(삭제 또는 주석)해줘:
 - 채팅 요청 본문에 `"think": true/false` 를 직접 넣던 부분
 - `num_predict / max_tokens` 같은 답 길이 상한을 직접 세팅하던 부분
 - 응답에서 `<think>` 태그나 모델 혼잣말을 잘라내려고 직접 후처리하던 코드
- 단, 이걸 지워서 동작이 깨지지 않는지 확인하고, 애매하면 지우기 전에 알려줘.

3) 거절 규칙 확인·추가 (안전 핵심)

- 백엔드의 시스템 프롬프트(모델에게 주는 지시문)를 찾아줘.
- 거기에 "제공된 근거 자료에 없는 내용은 지어내지 말고 '자료에 없어 확인되지 않습니다'라고 답하라"는 규칙이 있는지 확인하고, 없으면 추가해줘. 출처(근거 조각)를 함께 밝히도록도 지시해줘.

- 이 앱은 교육용 더미 자료만 쓰며, 실제 간호 적용은 부서 프로토콜 확인이 필요하다는 안내 문구도 답변 성격에 맞게 시스템 프롬프트에 넣어줘.

4) 마무리

- 바꾼 파일과 바뀐 줄을 요약해서 알려줘.
- 하드코딩된 주소가 더 남아있지 않은지 다시 한 번 훑어줘.
- 실제 환자정보나 실제 프로토콜을 코드에 넣지 말라고 나에게 상기시켜줘.

③ 이 프롬프트가 실제로 바꾸는 것

- 모델 호출 주소를 전부 :11500(공유 게이트웨이) 로 통일하고, 한 변수로 모아 관리하게 만 든다.
- `think` 세팅· `num_predict` (길이 상한)· `<think>` 후처리 등 게이트웨이가 자동 처리하는 코드를 제거해 백엔드가 단순해진다.
- 시스템 프롬프트에 “자료에 없으면 확인되지 않습니다” 거절 규칙과 출처 표기 지시를 확인·보강한다.
- 프론트가 모델 서버를 직접 부르는 보안 위반이 있으면 백엔드(:8000)만 부르도록 바로 잡는다.

④ 불인 뒤 확인

1. 게이트웨이 생존 확인

```
curl http://121.138.151.6:11500/health
```

응답이 오면 정상. (모델 목록까지 보려면 `curl http://121.138.151.6:11500/api/tags` — 목록에 `qwen3.6:35b-a3b` · `bge-m3` 가 보이면 좋음.)

2. 앱 기동

```
uvicorn app:app --port 8000
curl http://127.0.0.1:8000/health
```

`{"ok":true,"ollama":true}` 처럼 `ollama:true` 면 내 백엔드 → 게이트웨이 연결 정상. 이어서 브라우저에서 `index.html` 을 열어 채팅창 확인.

3. 대표 질문 1개 (더미 자료 기준)

수혈 검사 전후에 뭘 확인해야 해?

기대: 답과 함께 출처(예: “근거: 수혈”) 가 뜨고, `<think>` 태그나 모델 혼잣말 없이 깔끔한 답만 나온다. 혼잣말이 섞이면 주소가 `:11500` 인지 다시 확인.

⑤ 안전수칙 (대외비 — 가장 중요)

- **실제 임상정보 절대 금지** — 환자명·등록번호·주민번호·병실+이름, 실제 간호 프로토콜 전문을 입력창·코드에 넣지 마세요. 넣은 내용은 원격 모델로 나갑니다.
- **더미(가짜)만 사용** — 3주차 가짜 8조각(EGD·대장내시경·수혈·조영CT·MRI·채혈·심전도·복부초음파)처럼 비식별 교육용 예시로만.
- **외부(상용) 모델 전송 금지** — ChatGPT·Claude 등 사내 게이트웨이 밖 모델에 간호 자료를 붙여넣지 마세요. 호출 대상은 오직 `http://121.138.151.6:11500` 뿐입니다.

- **거절 규칙 유지** — 근거에 없으면 “확인되지 않습니다”로 답하게 두고, 모델 답은 참고용. 실제 간호 적용은 부서 프로토콜·담당자 확인을 거치세요.
- **프론트는 백엔드만** — `index.html` 에서 `:11500 · ollama` 를 직접 부르지 마세요. 테스트가 끝나면 띄운 `uvicorn` 을 내려(Ctrl+C) 공유 GPU 부하를 남기지 마세요.