

11. 정보지원팀 — 전산장애 · 공유 API 붙이기 프롬프트

1) 한 줄 목표

내 전산장애 안내 챗봇(근거기반 RAG)이 각자 띄우던 모델 주소 대신 **공유 게이트웨이 (:11500)** 를 쓰도록 바꾸고, 자료에 없는 질문은 “확인되지 않습니다”로 거절하게 만든다.

2) 복붙 프롬프트 (Claude Code에 그대로 붙여넣기)

아래 회색 박스를 통째로 복사해서 Claude Code 입력창에 붙여넣으세요. 손으로 코드를 고치지 않습니다 — AI에게 시킵니다.

너는 내 코드를 고쳐 주는 도우미야. 아래 작업을 순서대로 해줘.

[배경]

- 내 앱은 정보지원팀 전산장애/업무 안내용 근거기반(RAG) 챗봇이야.
프론트(HTML 화면)는 내 백엔드만 호출하고, 모델(임베딩·채팅) 호출은 백엔드가 해.
- 지금까지는 각자 띄운 모델 서버(11434 포트)를 썼는데,
이제 공유 게이트웨이 `http://121.138.151.6:11500` 으로 바꿔야 해.
- 게이트웨이가 `think:false`(생각 누출 차단), 응답 길이 상한,
모델명 정규화를 자동으로 처리해줘. 그래서 그 처리 코드는 이제 필요 없어.

[작업 1] 모델 주소를 게이트웨이로 변경

- 본인 앱의 백엔드 코드에서 모델 서버 주소가 들어간 줄을 모두 찾아줘.
(예: `OLLAMA_URL` 같은 변수, 또는 `http://...:11434`, `localhost:11434`, `127.0.0.1:11434`)
- 그 주소를 전부 `http://121.138.151.6:11500` 로 바꿔줘.
- 임베딩(검색)·생존확인(tags)·채팅 세 가지 호출이 모두 이 주소를 쓰는지 확인해줘.
- 주소를 바꿀 곳이 한 군데뿐이 되도록, 주소는 코드 상단의 변수 한 곳에 모아 두고 나머지는 그 변수를 참조하게 정리해줘.

[작업 2] 이제 불필요해진 코드 정리

- 요청 본문(payload)에 `think` 값을 직접 넣거나 `<think>` 태그를 잘라내는 처리가 있으면
게이트웨이가 대신 해주니 지워도 되는지 알려주고, 안전하면 정리해줘.
- 응답 길이 상한(`num_predict` / `max_tokens` 등)을 코드에서 강제로 넣던 부분이 있으면
게이트웨이가 상한을 걸어주니 제거하거나 주석으로 남겨줘.
- 모델 이름을 특정 형태로 바꿔치기하던 코드가 있으면, 게이트웨이가 정규화하니
단순하게 정리해줘.
- 단, 확신이 안 서는 부분은 지우지 말고 나한테 먼저 물어봐줘.

[작업 3] 거절 규칙을 시스템 프롬프트에 확인·추가

- 본인 앱의 시스템 프롬프트(모델에게 주는 지시문/역할 문구)를 찾아줘.
- 아래 규칙이 이미 있으면 그대로 두고, 없으면 추가해줘:
 - "제공된 자료(검색된 근거 조각)에 없는 내용은 지어내지 말고
 - '확인되지 않습니다'라고 답한다. 서버 비밀번호·관리자 계정·상세 IP 대역 같은
 - 보안정보나 환자 개인정보를 묻는 질문에는 모델을 부르지 말고
 - '보안상 안내하지 않습니다'로 답한다.
 - 답변에는 근거가 된 출처 태그를 함께 표시한다."

[작업 4] 요약

- 무엇을 어디서(파일명·줄 위치) 바꿨는지 3~4줄로 알려줘.
- 내가 직접 확인해볼 방법(curl, 앱 실행)도 한 줄로 알려줘.

3) 이 프롬프트가 실제로 바꾸는 것

- 본인 앱의 모델 주소 줄(11434 → **121.138.151.6:11500**)을 전부 게이트웨이로 교체합니다.
- **think** 처리·응답 길이 상한·모델명 변환 등 게이트웨이가 대신 해주는 코드를 정리합니다.
- 시스템 프롬프트에 “자료에 없으면 확인되지 않습니다” + “보안정보는 안내하지 않습니다” 거절 규칙을 확인·추가합니다.
- 결과적으로 생각(혼잣말) 누출이 사라지고, 여러 명이 몰려도 빈 답 없이 안정적으로 동작합니다.

4) 불인 뒤 확인

(1) 게이트웨이 생존 확인

```
curl http://121.138.151.6:11500/health
```

정상 응답이 오면 공유 서버가 살아 있는 것입니다.

(2) 내 앱 기동 후 백엔드 확인

```
uvicorn app:app --port 8000
```

```
curl http://127.0.0.1:8000/health
```

예: {"ok":true,"ollama":true,...} → "ollama":true 면 게이트웨이까지 연결 정상

그다음 프론트를 띄웁니다. **index.html** 을 더블클릭하면 CORS로 막힐 수 있으니, 같은 폴더에서 **python -m http.server 5500** 실행 후 브라우저에서 **http://127.0.0.1:5500/index.html** 을 여세요.

(3) 대표 질문 1개

화면 입력창에 아래를 넣어 봅니다.

CD 분석이 안 돼요

기대 동작: 출처 태그(예:  외부영상CD-CD분석중)와 함께 “CD-ROM 교체, 담당은 정보지원팀” 같은 근거 답이 나오고, **<think>** 같은 혼잣말이 섞이지 않습니다. 자료에 없는 질문에는 “확인되지 않습니다”가 나오면 성공입니다.

5) 안전 수칙

- **더미·비식별 데이터만** — 자료 조각과 테스트 질문은 모두 연습용·비식별만 사용합니다. 실제 사례·내부 통계·담당자 실명/연락처는 넣지 않습니다.
- **환자 개인정보·보안정보 금지** — 환자명·등록번호는 물론 서버 비밀번호·관리자 계정·상세 IP 대역도 입력 금지. 이런 질문에는 모델을 부르지 말고 “보안상 안내하지 않습니다”로 차단합니다.
- **거절 규칙 유지** — 자료(검색 근거)에 없는 내용은 지어내지 말고 “확인되지 않습니다”로 답하게 합니다.
- **분리 강제** — 화면(`index.html`)에서 모델을 직접 부르지 말고, 모델 호출은 오직 백엔드(`:8000`) 경유로.
- **공유 서버 예절** — 게이트웨이 뒤 GPU는 모두가 함께 씁니다. 한 번에 한 질문씩, 테스트가 끝나면 `uvicorn` 을 내리세요(Ctrl+C). 모델 서버 주소(`:11500`)는 외부 공유 금지.